기초 파이썬

2026.9.23일

담당교수: 박진호

서강대학교 경제대학원
2026년 2학기

◈ 오늘의 학습 목표

◈ 이번 데이터 분석에서는 예측(predictions)을 실행

◉ 먼저, 관심 대상인 결과 변수(outcome variable)와 예측 변수(predictor) 간 관계를 그래프에서 하나의 직선(a line)로 요약하는 방법을 학습할 예정

◉ 이어서, 예측 변수의 특정한 값이 주어질 때 이러한 요약 정보를 사용하여 가장 가능성이 높은 결과의 값을 추정할 예정

- 참조:

▸ James, Gareth, Witten, Daniela , Hastie, Trevor , Tibshirani, Robert , Hastie, Trevor(2023), An introduction to statistical learning : with applications in python. 번역판(2024).

▸ 최필선·민인식(2024), (데이터과학의 첫걸음) 빅데이터분석 with Python, 지필미디어.

6장 선형회귀모형

1. 통계적 학습

□ 통계적 학습(statistical learning)은 통계 모형(statistical model)을 통해 데이터를 이해하고 학습시키는 것을 말함

o 즉, 모형 또는 기계를 통계적 방법으로 학습시키는 것

o 통계 모형에서

입력변수: 예측변수(predictors), 독립변수(independent variables), 특성(features) 등

출력변수: 반응(response) 또는 종속변수(dependent variable) 등으로도 불림

□ 통계적 학습은 크게 지도학습과 비지도학습으로 분류됨

o 지도학습(supervised learning): 입력변수를 이용해서 출력변수를 추정 또는 예측하는 모형을 만드는 것

▸ 예: 시장세분화(market segmentation)를 통한 마케팅 전략에서 고객별로 구매액, 구매횟수, 방문 횟수 등의 반응변수를 기준으로 시장을 세분화하는 경우

→ 통계적 학습이 어떤 기준 또는 목표 아래서 진행되는 것

o 비지도학습(unsupervised learning): 입력변수는 있지만 출력변수가 없는데, 출력변수가 없음에도 불구하고 데이터로부터 어떤 관계와 구조에 대해 알아내고자 함.

명시적인 정답없이 데이터의 숨겨진 구조나 패턴을 찾는 머신러닝 방법중 하나로 클러스터링(예: k-평균 알고리즘), 차원 축소(예: 주성분분석 PCA) 등이 포함됨

▸ 예: 시장세분화(market segmentation)를 통한 마케팅 전략에서 오픈되지 않은 온라인 쇼핑몰의 경우 잠재적 고객 정보만 있고 제품 구매액, 방문 횟수 등의 데이터는 갖고 있지 않은 상태에서 잠재적 고객을 세분화해야 하는 경우

2. 회귀 모형

2.1 회귀모형의 개념

□ 현실에서 어떤 결과 Y가 여러 요인 X와 어떤 관계가 있는지 알고 싶은 경우가 많음

o 예: 학생의 성적은 공부 시간, 수업 참여도 등 여러 요인과 관련될 수 있음
경제성장률은 투자, 소비, 수출 등 다양한 경제변수와 관련될 수 있음

□ 이러한 관계를 통계적으로 표현하면 다음과 같음

$$Y = f(X) + \epsilon$$

- 여기서
X=($X_1, X_2, ..., X_p$)는 Y를 설명하거나 예측하는 데 사용하는 p개의 예측변수(예측변수),
$f(X)$는 X와 Y 사이의 체계적인 관계를 나타내는 함수

□ 실제로는 f의 구체적 형태를 알 수 없기 때문에 f를 미지의 함수(unknown function)라 함

□ ϵ 은 X만으로만 설명되지 않는 부분을 나타내는 오차항(error term)

- o 관측되지 않은 요인, 측정오차, 우연적인 변동 등이 포함될 수 있음

□ 따라서 동일한 X값을 갖더라도 Y가 항상 동일하게 나타나는 것은 아님

- o $Y = f(X) + \epsilon$에서 $f(X)$가 동일하더라도 ϵ 이 달라질 수 있기 때문

□ 즉, Y는 X에 의해 완전히 결정되는 것이 아니라 확률적으로 변동하며, 이것이 회귀모형을 단순한 함수식이 아니라 확률적 모형으로 이해하는 이유

□ 회귀분석에서는 관측된 데이터를 이용하여 미지의 함수 f를 추정하고, 이를 통해 크게 두 가지 목적을 달성하고자 함

❶ 예측(prediction): 새로운 X가 주어졌을 때 Y를 예측

❷ 추론(inference): X와 Y 사이의 관계를 이해

2.2 예측

□ 회귀모형의 주요 목적 중 하나는 새로운 관측값에 대해 Y의 값을 예측(prediction)하는 것

□ 실제 함수 f는 알 수 없으므로 데이터를 이용하여 추정한 함수 $\hat{f}$를 사용

□ 새로운 관측값 X가 주어졌을 때 예측값은 다음과 같이 표현 가능

$$\hat{Y} = \hat{f}(X)$$

□ $\hat{Y}$는 주어진 X에서 Y가 나타낼 것으로 예상되는 체계적인 수준(평균 수준)을 의미

- o 개별 관측값을 하나씩 완벽하게 맞추는 것이 아니라 X와 Y 사이에 존재하는 일반적인 패턴(평균적인 패턴)을 이용하여 예측

□ 그러나 아무리 정교한 방법을 사용하더라도 예측에는 오차가 발생할 수 있음

- o $Y = f(X) + \epsilon$에서 실제 Y에는 우리가 직접 예측하기 어려운 ϵ 이 포함되어 있기 때문

◆ 예측 오차는 크게 축소가능 오차와 축소불가능 오차로 구분할 수 있음

❶ 축소가능 오차(reducible error)

□ 실제 함수 f를 정확히 알지 못하여 $f(X)$와 $\hat{f}(X)$ 사이에 차이가 나기 때문에 발생

$$f(X) \neq \hat{f}(X)$$

□ 이 오차는 ① 적절한 모형의 선택, ② 더 많은 정보, ③ 데이터의 활용 등을 통해 줄일 수 있음

□ 따라서 통계적 학습의 중요한 목표 중 하나는 f를 보다 더 정확히 추정하여 이러한 오차를 줄이는 것

❷ 축소불가능 오차(irreducible error)

□ 데이터 생성 과정 자체에 포함되어 있는 오차항 ϵ 으로부터 발생하는 **오차**

□ 설령 f를 완변하게 추정하여 $\hat{f}(X) = f(X)$가 되더라도 $Y = f(X) + \epsilon$이므로 실제 Y와 예측값 사이에는 차이가 발생할 수 있음

□ 따라서 이러한 오차는 f를 추정하는 방법을 개선하는 것만으로는 제거할 수 없음

◇ 예측의 목표는 모든 관측값을 완벽하게 맞추는 것이 아니라, 예측 가능한 부분인 $f(X)$를 최대한 정확하게 추정하는 것

o 그 과정에서 축소가능한 오차은 줄이되, 축소불가능한 오차는 불확실성으로서 받아들여야 함

2.3 추론

□ 회귀모형의 목적이 항상 예측에만 있는 것이 아님

□ 경제학이나 사회과학에서는 예측 자체보다 변수들 사이에 어떤 관계가 존재하는지 **이해**하는 것이 중요한 경우가 많으며, 이를 추론(inference)이라고 함

□ 추론에서는 다음과 같은 질문에 관심이 있음

- o 어떤 예측변수가 반응변수 Y와 연관되어 있는가?
- o 특정 변수 X_j의 변화는 Y와 어느 정도의 관계가 있는가?
- o X와 Y 사이의 관계는 선형적인가, 비선형적인가?
- o 추정된 관계에는 어느 정도의 통계적 불확실성이 존재하는가?

□ 따라서 예측에서는 "새로운 Y를 얼마나 잘 예측할 수 있는가?" 가 중요한 반면,
추론에서는 "X와 Y 사이에는 어떤 관계가 있는가?" 가 중요

<참고> 추론과 인과관계

□ X와 Y 사이에 통계적인 관계가 있다는 사실만으로 X가 Y의 원인이라고 결론 내릴 수는 없음

□ 정책의 효과와 같은 인과관계(causal relationship)를 분석하려면 교란요인, 연구설계 등 추가적인 조건을 고려해야 함

2.4 예측과 추론에 적합한 모형

□ **어떤 모형을 선택할 것인가**는 분석의 목적과 밀접하게 관련됨

□ 추론이 중요한 경우, 변수 간 관계를 쉽게 설명할 수 있는 해석 가능성(interpretability)이 중요

- o 선형회귀와 같은 단순한 모형은 각 변수와 Y 사이의 관계를 계수를 통해 비교적 쉽게 해석할 수 있음
- o 반면 너무 단순한 모형은 데이터에 있는 복잡한 관계를 충분히 포착하지 못할 수 있음

□ 예측이 중요한 경우, 예측 정확도(prediction accuracy)가 중요

- o 복잡하고 유연한 모형은 데이터에 존재하는 비선형적 관계나 복잡한 패턴을 포착하는 데 유리
- o 그러나 모형이 복잡해질수록 결과를 직관적으로 해석하기 어려워질 수 있음

□ 따라서 실제 분석에서는 예측 정확도와 해석 가능성 간 상충관계(trade-off)를 고려해 선택해야 함

2.5 훈련 데이터

□ 지금까지 논의한 f를 실제로 추정하기 위해서는 관측된 데이터가 필요

□ 연구자가 관측한 n개 데이터를 $(x_1,y_1),(x_2,y_2),...,(x_n,y_n)$이라고 하자.

□ 이러한 관측자료를 이용하여 f를 추정하며, 모형을 학습시키는 데 사용되는 데이터를 훈련 데이터(training data)라고 함

□ 여기서 중요한 것은 추정된 $\hat{f}$가 훈련 데이터에만 잘 맞아서는 안 된다는 것

□ 우리가 원하는 것은 학습에 미사용된 새로운 데이터에서도 좋은 성능을 보이는 모형

□ 따라서 모형의 성능을 평가할 때에는 훈련 데이터에서 얼마나 잘 맞는지만 보는 것이 아니라 새로운 데이터에서 얼마나 잘 작동하는지도 확인해야 함

o 이후 테스트 데이터(test data), 교차검증(cross-validation) 등의 방법을 이용해 이를 평가

2.6 f를 어떻게 추정할 것인가?

□ 훈련 데이터를 이용하여 f를 추정하는 방법은 매우 다양하지만, 크게 파라미터형(parametric) 방법과 비파라미터형(non-parametric) 방법으로 구분할 수 있음

2.6.1 파라미터형 방법

□ 파라미터형 방법은 1) **f의 함수 형태를 먼저 가정(선택)**한 다음, 2) 데이터를 이용하여 그 함수의 파라미터를 추정하는 방법

o 예를 들어 $f(X) = \beta_0 + \beta_1 X_1$와 같이 선형관계를 가정하면, 미지의 함수 f 전체를 직접 찾는 대신 $\beta_{0,}\beta_1$을 추정하면 됨

◆ 일반적으로 다음 두 단계를 거침

❶ f 함수의 형태를 선택

$$f(X) = \beta_0 + \beta_1 X_1$$

❷ 훈련 데이터를 이용하여 파라미터를 추정

$$\beta_0, \beta_1 \quad \rightarrow \quad \hat{\beta}_0, \hat{\beta}_1$$

□ 복잡한 함수 전체를 추정하는 문제를 몇 개의 파라미터를 추정하는 문제로 단순화할 수 있어 계산과 해석이 비교적 쉬움

□ 반면 처음 가정한 함수 형태가 실제 f와 크게 다르면 실제 관계를 제대로 포착하지 못할 수 있으며, 이를 모형설정 오류(model misspecification)라고 함

2.6.2 비파라미터형 방법

□ 비파라미터형(non-parameteric) 방법은 **f의 구체적인 함수 형태를 미리 정하지 않고**, 데이터에서 나타나는 패턴을 이용하여 f를 유연하게 추정하는 방법

"Let the data speak for itself."

□ 즉, 함수 형태를 연구자가 미리 강하게 제한하기보다 데이터가 보여주는 패턴에 따라 관계를 추정한다는 의미

□ 따라서 실제 관계가 비선형이거나 복잡한 경우에도 이를 보다 유연하게 포착할 수 있음

□ 그러나 유연성에는 대가가 따름

- o 일반적으로 정확한 추정을 위해 더 많은 데이터가 필요
- o 훈련 데이터에 지나치게 맞추는 과적합(overfitting)의 위험이 있음

◆ 어느 한 방법이 항상 우월한 것은 아니며, 분석 목적과 데이터의 특성에 따라 적절한 모형을 선택해야 함

2.7 모형의 유연성과 해석 가능성

□ 앞에서 살펴본 여러 통계적 학습 방법은 유연성(flexibility)의 정도가 서로 다름

□ 유연성이란 모형이 데이터에 존재하는 다양한 형태의 관계를 얼마나 자유롭게 표현할 수 있는가를 의미

- o 단순한 선형모형은 표현할 수 있는 관계의 형태가 제한적이므로 유연성이 낮음
- o 비선형 모형이나 복잡한 머신러닝 모형은 다양한 형태의 관계를 표현할 수 있으므로 유연성이 높음

□ 일반적으로 모형이 단순할수록 변수와 반응변수 사이의 관계를 해석하기 쉬움

- o 예를 들어 선형모형 $Y = \beta_0 + \beta_1 X_1 + \epsilon$에서는 β_1을 이용하여 X와 Y 간 관계를 비교적 명확하게 해석할 수 있음

□ 반면 모형의 유연성이 높아질수록 여러 변수와 비선형적인 관계가 복잡하게 결합될 수 있기 때문에 개별 변수와 Y 간 관계를 직관적으로 설명하기 어려워질 수 있음

□ 그러나 유연한 모형이 항상 더 좋은 모형을 의미하는 것은 아님

- o 너무 단순한 모형은 데이터의 중요한 패턴을 놓칠 수 있음
- o 너무 유연한 모형은 관측된 데이터에 과도하게 맞추어져 새로운 데이터에 대한 예측력이 떨어질 수 있음

□ 따라서 분석에서는 연구 목적과 데이터의 특성을 고려하여 적절한 수준의 유연성을 가진 모형을 선택하는 것이 중요

◆ 모형은 단순할수록 해석하기 쉽지만 복잡한 관계를 놓칠 수 있고, 유연할수록 복잡한 관계를 포착할 수 있지만 해석과 일반화가 어려워질 수 있다.

2.8 회귀와 분류

□ 지금까지는 주로 반응변수 Y가 수치로 측정되는 경우를 중심으로 설명하였음

□ 그러나 통계적 학습에서는 **반응변수의 유형**에 따라 문제를 크게 회귀와 분류로 구분할 수 있음

❶ 회귀(regression)

□ 반응변수 Y가 정량적(quantitative)인 값을 가지는 경우

- 예: 소득, 주가, 매출액, GDP 성장률, 주택가격 등

□ 이러한 수치형 값을 설명하거나 예측하는 문제를 회귀(regression)라고 함

- 예를 들어, 주택가격 = f(면적, 위치, 건축연도) + ε

  에서 주택가격은 수치로 측정되므로 회귀 문제에 해당

❷ 분류(classification)

□ 반응변수 Y가 범주형(categorical)인 값을 가지는 경우

o 예: 부도/정상, 취업/미취업, 구매/비구매 등

□ 관측값이 어느 범주에 속하는지를 예측하는 문제를 분류(classification)라고 함

o 예) $Y = \begin{cases} 1 & \text{기업부도} \\ 0 & \text{정상} \end{cases}$ 와 같이 반응변수가 범주를 나타내면 분류 문제에 해당

반응변수 Y	분석 문제	예
정량적	회귀	소득, 매출액, GDP 성장률
범주형	분류	부도/정상, 구매/비구매

<참고> 로지스틱 회귀

□ 로지스틱 회귀(logistic regression)는 이름에 회귀가 들어가지만, 주로 범주형 반응변수를 다루는 분류 방법으로 사용됨

□ 이에 대해서는 뒤의 분류 모형에서 자세히 살펴봄

3. 모형의 정확도 평가

□ 지금까지 데이터를 이용하여 미지의 함수 f를 추정하는 여러 접근 방법을 살펴보았음

□ 그렇다면 서로 다른 모형 가운데 어떤 모형이 더 좋은가?

□ 예측을 목적으로 하는 경우 가장 기본적인 평가방법은 모형의 예측값과 실제 관측값의 차이, 즉 **예측오차**를 비교하는 것

실제값 y_i vs. 예측값 $\hat{y}_i$

□ 회귀 문제에서는 이러한 예측오차를 평가하는 대표적인 지표로 평균제곱오차(MSE)를 사용할 수 있음

3.1 평균제곱오차(MSE)

□ 실제 관측값을 y_i, 모형에 의한 예측값을 $\hat{y}_i$라고 하면 개별 관측값의 예측오차는 다음과 같이 나타낼 수 있음

$$y_i - \hat{y}_i$$

□ 그러나 양(+)의 오차와 음(-)의 오차를 단순히 더하면 서로 상쇄될 수 있으므로 오차를 제곱하여 평가

□ 평균제곱오차(MSE: Mean Squared Error)는 각 관측값의 예측오차를 제곱한 후 평균한 값

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y})^2$$

여기서
- y_i : i 번째 실제 관측값
- $\hat{y}_i$: i 번째 예측값
- n : 관측값의 수

□ MSE가 작다는 것은 실제값과 예측값 사이의 차이가 전반적으로 작다는 것을 의미

<참고> 왜 오차를 제곱하는가?

□ 양(+)과 음(-)의 오차가 서로 상쇄되는 것을 방지

□ 큰 오차에 상대적으로 더 큰 가중치를 부여하는 효과가 있음

3.2 훈련 MSE와 테스트 MSE

□ MSE 계산에서 중요한 것은 어떤 데이터에서 오차를 측정하는가임

❶ 훈련 MSE(Training MSE)

□ 모형을 학습시키는 데 사용한 훈련 데이터에서 계산한 MSE

□ 훈련 MSE가 작다는 것은 모형이 이미 학습한 데이터에 잘 맞는다는 것을 의미

❷ 테스트 MSE(Test MSE)

□ 모형 학습에 사용하지 않은 새로운 데이터에서 계산한 MSE

□ 테스트 MSE는 모형이 새로운 데이터에서도 얼마나 잘 작동하는지를 평가

□ 예측이 목적이라면, 가장 중요한 것은 훈련 MSE보다 새로운 데이터에서의 예측 오차

□ 따라서 훈련 MSE가 매우 작다고 해서 반드시 좋은 예측모형이라고 할 수 없음

◆ 좋은 예측 모형은 이미 본 데이터를 잘 설명하는 데 그치지 않고, 보지 않은 새로운 데이터에서도 잘 작동해야 함

3.3 모형 유연성과 예측 오차

□ 모형의 유연성이 증가하면, 훈련 데이터에 존재하는 복잡한 패턴까지 포착할 수 있음

□ 따라서 일반적으로 모형이 유연해질수록, 훈련 MSE는 감소하는 경향이 있음

□ 그러나 테스트 데이터에서는 반드시 그렇지 않음

❶ 유연성이 너무 낮은 경우

□ 모형이 지나치게 단순하여 데이터에 존재하는 중요한 패턴을 충분히 포착하지 못함

□ 이를 과소적합(underfitting)이라고 함

❷ 적절한 유연성을 가진 경우

□ 데이터의 중요한 패턴을 포착하면서 불필요한 변동까지 따라가지는 않음

□ 새로운 데이터에서도 상대적으로 좋은 예측성능을 보일 수 있음

3 유연성이 지나치게 높은 경우

□ 훈련 데이터의 일반적인 패턴뿐 아니라 우연적인 변동까지 학습할 수 있음

□ 이를 과적합(overfitting)이라고 함

□ 따라서 테스트 MSE는 모형의 유연성이 증가함에 따라 처음에는 감소하다가 지나치게 유연해지면 다시 증가하는 U자형 관계를 보일 수 있음

3.4 편향-분산 상충관계

□ 그렇다면 왜 모형이 지나치게 단순하거나 지나치게 유연하면 테스트 오차가 커질 수 있을까?

□ 이를 이해하기 위한 중요한 개념이 편향-분산 상충관계(Bias-Variance Trade-off)임

□ 새로운 관측값 x_0에 대한 기대 테스트 MSE는 세 가지 요소로 분해할 수 있음

$$E[(Y_0 - \hat{f}(x_0))^2] = \underbrace{Bias[\hat{f}(x_0)]^2}_{\text{편향}^2} + \underbrace{Var[\hat{f}(x_0)]}_{\text{분산}} + \underbrace{Var(\epsilon)}_{\text{축소불가능 오차}}$$

❶ 편향(Bias)

□ 추정한 모형이 실제 함수 f와 체계적으로 얼마나 차이가 나는가를 나타냄

□ 모형이 지나치게 단순하면 실제 관계를 충분히 표현하지 못하여 편향이 커질 수 있음

단순한 모형 ⇒ 높은 Bias 가능

❷ 분산(Variance)

□ 훈련 데이터가 달라졌을 때 추정된 모형 $\hat{f}$가 얼마나 크게 달라지는가를 나타냄

□ 지나치게 유연한 모형은 훈련 데이터의 작은 변화에도 민감하게 반응할 수 있으므로 분산이 커질 수 있음

유연한 모형 ⇒ 높은 Variance 가능

❸ 축소불가능 오차(Irreducible Error)

□ 데이터 생성과정에 포함된 ϵ 으로부터 발생하는 본질적인 불확실성

□ 모형을 아무리 잘 추정하더라도 완전히 제거할 수 없음

◆ 편향과 분산의 상충관계

모형	Bias	Variance	주요 위험
지나치게 단순	높음	낮음	과소적합
지나치게 유연	낮음	높음	과적합
적절한 복잡성	균형	균형	일반화 성능 향상

◇ 따라서 모형의 유연성을 높이는 것이거나 낮추는 것이 항상 좋은 것도 아님

◇ 좋은 예측모형을 만들기 위해서는 편향과 분산 사이의 적절한 균형을 찾아 테스트 오차를 낮추는 것이 중요

4. 회귀모형

4.1 단순선형회귀

□ 단순선형회귀(simple linear regression)는 하나의 설명변수 X를 사용하여 반응변수 Y와의 선형적인 관계를 분석하는 모형

$$Y = \beta_0 + \beta_1 X + \epsilon$$

여기서
- Y : 반응변수(response variable)
- X : 설명변수 또는 예측변수(predictor)
- β_0: 절편(intercept)
- β_1: 기울기(slope)
- ϵ : 오차항(error term)

□ β_0와 β_1은 X와 Y의 관계를 결정하는 회귀계수(regression coefficients) 또는 파라미터(parameter)

□ 특히 β_1은 X가 한 단위 증가할 때 Y가 평균적으로 얼마나 달라지는지를 나타냄

□ 그러나 모집단의 실제 β_0와 β_1은 알 수 없으므로 표본 데이터를 이용하여 이를 추정

$$\beta_0,\ \beta_1 \quad \rightarrow \quad \hat{\beta}_0,\ \hat{\beta}_1$$

□ 추정된 회귀식은 $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$

□ 새로운 $X = x$가 주어지면 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$를 이용하여 Y를 예측할 수 있음

4.1.1. OLS와 잔차

□ 그렇다면 표본 데이터를 이용하여 $\hat{\beta}_0$와 $\hat{\beta}_1$을 어떻게 구할 것인가?

□ n개의 관측자료 $(x_1,y_1),(x_2,y_2),...,(x_n,y_n)$가 있다고 하자.

□ i 번째 관측값에 대한 회귀모형의 예측값은 $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$

□ 실제 관측값 y_i와 예측값 $\hat{y}_i$ 사이에는 일반적으로 차이가 존재하며, 이를 잔차(residual)라 함

$$\hat{e}_i = y_i - \hat{y}_i \quad \text{즉, 잔차 = 실제값 - 예측값}$$

□ 최소제곱법(OLS: Ordinary Least Squares)은 모든 관측값의 잔차를 제곱하여 더한 잔차제곱합(RSS: Residual Sum of Squares)을 최소로 만드는 $\hat{\beta}_0$과 $\hat{\beta}_1$을 선택

$$\text{RSS} = \hat{e}_1^2 + \hat{e}_2^2 + ... + \hat{e}_n^2 = \sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

또는 $$\text{RSS} = \sum_{i=1}^{n} [y_i - (\hat{\beta}_0 - \hat{\beta}_1 x_i)]^2$$

◇ 따라서 OLS는 “RSS를 최소화하는 회귀선을 찾는 방법” 이라고 이해할 수 있음

Q. OLS에서 잔차는 수직 거리인가, 수평 거리인가?

□ 잔차는 동일한 x_i에서 실제 관측값 y_i와 예측값 $\hat{y}_i$의 차이: $\hat{e}_i = y_i - \hat{y}_i$

□ 따라서 일반적인 OLS 회귀에서 최소화하는 것은 y축 방향의 수직 거리(vertical distance)의 제곱합

□ 회귀선까지의 최단거리나 수평거리를 최소화하는 것이 아님

4.1.2 추정 예: Advertising 데이터

□ 실제 데이터를 이용하여 단순선형회귀를 추정해 보자

□ Advertising.csv 데이터는 광고비와 제품 판매량에 관한 자료로 다음과 같은 변수를 포함

변수	설명
Sales	제품 판매량(1,000개)
TV	TV 광고비(1,000달러)
Radio	라디오 광고비(1,000달러)
Newspaper	신문 광고비(1,000달러)

□ 여기서는 TV 광고비가 증가할 때 판매량이 얼마나 증가하는지를 선형회귀를 통해 추정

$$Sales_i = \beta_0 + \beta_1 TV_i + \epsilon_i$$

- 반응변수 Y : Sales
- 설명변수 X : TV

❶ 필요한 라이브러리 불러오기

```
import pandas as pd                    # 데이터 불러오기 및 DataFrame 처리
import seaborn as sns                  # 데이터 시각화
import matplotlib.pyplot as plt        # 데이터 시각화
import statsmodels.formula.api as smf  # 통계모형 추정 및 통계적 추론 수행
```

☐ statsmodels: 통계분석 라이브러리

☐ formula: 통계모형을 수식(formula) 형태로 작성할 수 있는 기능

☐ api: 해당 기능에서 주로 사용하는 함수들을 제공

☐ as smf: 긴 이름을 관례적으로 smf라는 약자 또는 별칭으로 사용

❷ 데이터 불러오기

```
advertising = pd.read_csv( “Advertising.csv“, usecols=[1, 2, 3, 4] )

advertising = advertising.rename(
    columns={ “radio“: “Radio“,  “newspaper“: “Newspaper“, “sales“: “Sales“ }
)

advertising.head()
```

□ usecols=[1, 2, 3, 4]는 CSV 파일에서 분석에 사용할 열만 선택하여 불러오는 것

<참고> Windows 파일 경로

□ Windows에서 전체 경로를 사용하는 경우 다음과 같이 raw string을 사용할 수 있음

```
advertising = pd.read_csv( r“D:\제6주차\Advertising.csv“ )
```

□ 문자열 앞의 r은 백슬래시(\)를 특수 기호로 해석하는 문제를 피하는 데 유용

4.1.3 산점도 및 추정 회귀선

□ 먼저 TV와 Sales의 관계를 산점도로 확인하고, 그 위에 추정된 선형회귀선을 표시

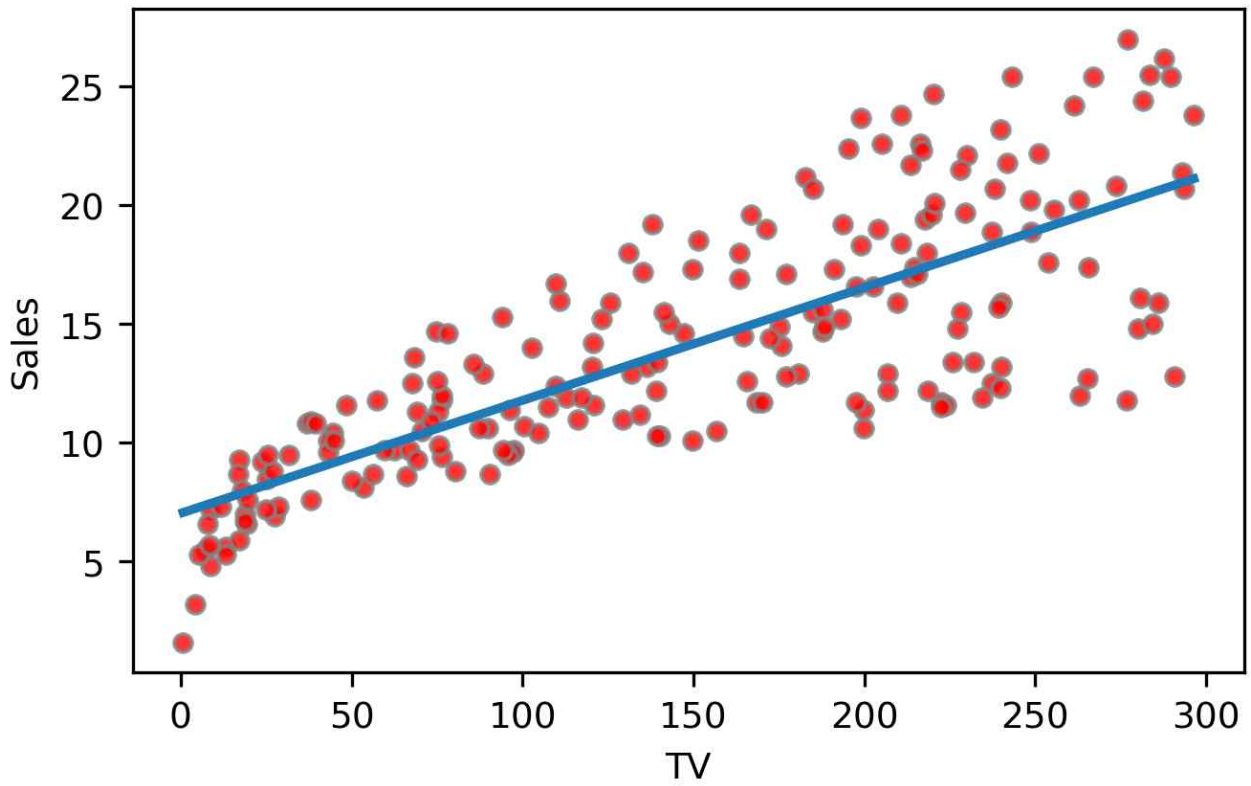
```
sns.regplot( data=advertising, x="TV", y="Sales", ci=None )

plt.xlabel("TV Advertising")
plt.ylabel("Sales")
plt.title("TV Advertising and Sales")
plt.show()
```

□ 그래프에서

- o 각각의 점 → 하나의 관측값 (TV_i, $Sales_i$)
- o 직선 → OLS로 추정한 회귀선
- o 관측값과 회귀선 사이의 수직 차이 → 잔차 e_i

□ OLS는 이러한 잔차들의 제곱합이 가장 작아지도록 회귀선을 결정


Sales
25
20
15
10
5
0
50
100
150
200
250
300
TV

4.1.4 Python을 이용한 회귀모형 추정

□ statsmodels를 이용하여 다음의 단순선형회귀모형을 추정

$$Sales_i = \beta_0 + \beta_1 TV_i + \epsilon_i$$

□ 기본 구문: smf.ols("y ~ x", data=df)

o ~의 왼쪽에는 반응변수(y), 오른쪽에는 설명변수(x)를 지정

□ 실제 데이터 사용

```
import statsmodels.formula.api as smf

model = smf.ols('Sales ~ TV', data=advertising)
olsfit = model.fit()

print(olsfit.summary())
```

□ model.fit()

o 선형회귀모형을 실제 데이터에 적합시키기 위해 fit 메소드를 호출

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                  Sales   R-squared:                       0.612
Model:                            OLS   Adj. R-squared:                  0.610
Method:                 Least Squares   F-statistic:                     312.1
Date:                Sat, 04 Apr 2026   Prob (F-statistic):           1.47e-42
Time:                        15:43:56   Log-Likelihood:                -519.05
No. Observations:                 200   AIC:                             1042.
Df Residuals:                     198   BIC:                             1049.
Df Model:                           1
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept      7.0326      0.458     15.360      0.000       6.130       7.935
TV             0.0475      0.003     17.668      0.000       0.042       0.053
==============================================================================
Omnibus:                        0.531   Durbin-Watson:                   1.935
Prob(Omnibus):                  0.767   Jarque-Bera (JB):                0.669
Skew:                          -0.089   Prob(JB):                        0.716
Kurtosis:                       2.779   Cond. No.                         338.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

4.1.5 회귀계수의 해석

□ 추정 결과는 대략 다음과 같음: $\widehat{Sales} = 7.0326 + 0.0475\,TV$

⇒ $\hat{\beta}_0$ = 7.0326, $\hat{\beta}_1$ = 0.0475

❶ 기울기 $\hat{\beta}_1$

□ TV 광고비가 1단위 증가할 때 Sales는 평균적으로 0.0475단위 증가한다는 것을 의미

□ TV 광고비의 단위가 1,000달러이고 Sales의 단위가 1,000개이므로 0.0475×1,000 = 47.5

⇒ TV 광고비가 1,000달러 증가할 때 판매량은 평균적으로 약 47.5개 증가하는 것으로 추정

❷ 절편 $\hat{\beta}_0$

□ $\hat{\beta}_0$ = 7.0326은 TV = 0, 즉 TV 광고비가 0일 때의 예상 판매량($\widehat{Sales} = 7.0326$)을 의미

□ 그러나 실제 데이터에 TV=0 또는 0에 가까운 관측값이 없다면, 이는 관측된 데이터의 범위를 벗어난 값에 대한 예측이므로 절편의 현실적인 의미는 제한적

◇ 기타

- 모형의 계수(coefficients): TV 광고 지출의 변화가 판매량에 어떤 영향을 미치는지 나타내는 값
- 계수의 표준오차(std.error), t 값(t-statistic), p 값(p-value): 계수의 통계적 유의성을 평가하는데 사용됨
- 결정계수(R-squared): 모형이 데이터의 변동성을 얼마나 잘 설명하는지를 나타내는 지표
- F-통계량(F-statistic)과 그 p 값: 모형 전체가 통계적으로 유의한지 평가

◇ 주의: 회귀계수와 인과관계

- 회귀계수는 일반적으로 다음과 같이 해석:
  "X가 1단위 증가할 때 Y는 평균적으로 β_1만큼 증가(감소)함"
- 그러나 이것이 "X의 증가가 Y의 증가를 원인으로서 발생시켰다"는 것을 의미하지 않음
- 회귀계수를 인과효과(causal effect)로 해석하려면, 다른 조건과 추가적인 가정이 필요

□ 추정 결과를 표로 생성

```
est = smf.ols('Sales ~ TV', advertising).fit()
print(est.summary().tables[1])
```

□ Statsmodels 라이브러리의 summary() 출력 결과는 총 3개의 표(Table 0, 1, 2)로 구성됨

- tables[0]: 모델 전체 개요 (R^2, Adjusted R^2, F-통계량, 관측치 수 등)
- tables[1]: coef(계수), std err(표준오차), t-통계량, p-value, 95% 신뢰구간)
- tables[2]: 잔차(Residuals)의 진단 정보 (Skewness, Kurtosis, Jarque-Bera, Durbin-Watson

	coef	std err	t	P&|t|	[0.025	0.975]
Intercept	7.0326	0.458	15.360	0.000	6.130	7.935
TV	0.0475	0.003	17.668	0.000	0.042	0.053

4.1.5 회귀계수의 통계적 추론

□ 앞에서 표본자료를 이용하여 회귀계수 β_0와 β_1을 추정하였음 ($\beta_0,\ \beta_1 \rightarrow \hat{\beta}_0,\ \hat{\beta}_1$)

□ 그러나 $\hat{\beta}_1$은 하나의 표본에서 계산한 추정값(estimate)이며, 모집단의 실제 회귀계수 β_1과 일치한다고 보장할 수 없음

$$\hat{\beta}_j \neq \beta_j$$

o 이는 모집단 전체가 아니라 일부 표본을 이용하여 회귀계수를 추정하기 때문

□ 동일한 모집단에서 서로 다른 표본을 추출하면 서로 다른 추정값을 값을 얻을 수 있음

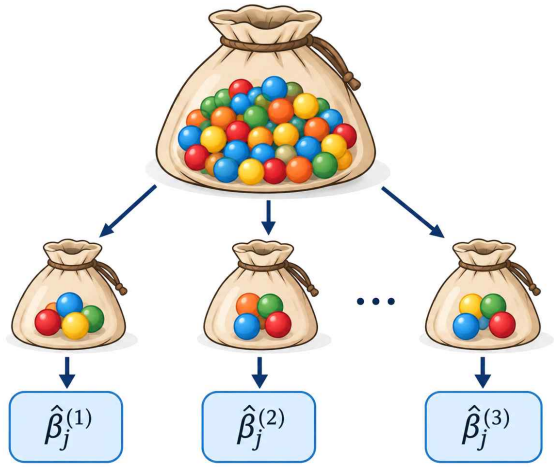
표본 1 $\rightarrow \hat{\beta}_j^{(1)}$,

표본 2 $\rightarrow \hat{\beta}_j^{(2)}$,

표본 3 $\rightarrow \hat{\beta}_j^{(3)}$

$$\hat{\beta}_j^{(1)} \neq \hat{\beta}_j^{(2)} \neq \hat{\beta}_j^{(3)}$$

β_j=모집단의 j번째 회귀계수



□ 즉, 추정계수는 표본에 따라 변동하며 여기에는 표본추출에 따른 불확실성이 존재

□ 통계적 추론(statistical inference)의 목적은 이러한 불확실성을 고려하여, 표본에서 얻은 $\hat{\beta}_j$을 바탕으로 모집단의 β_j에 대해 판단하는 것

□ 이를 위해 다음과 같은 개념을 차례로 살펴봄

$$\text{추정계수} \rightarrow \text{표준오차} \rightarrow \begin{cases} \text{신뢰구간} \\ \text{가설검정} \end{cases}$$

▸가설검정에서는 귀무가설 → t-통계량 → p-value → 통계적 판단의 순서로 진행

4.1.5.1 표준오차

□ 동일한 모집단에서 표본을 반복하여 추출한다면, 표본마다 서로 다른 회귀계수 $\hat{\beta}_j$가 추정될 수 있음

□ 이와 같이 반복표본에서 나타나는 $\hat{\beta}_j$의 분포를 표본분포(sampling distribution, SD)라고 하며, 그 표준편차를 표준오차(standard error, SE)라고 함

▸ $SE(\hat{\beta}_j)$: 표본이 달라질 때, $\hat{\beta}_j$이 얼마나 변동하는지를 나타내는 값

□ 그러므로 표준오차는 회귀계수 추정의 정밀도를 나타냄

- o 표준오차가 작음 → 표본이 달라져도 추정계수가 상대적으로 적게 변함
  → 추정의 정밀도가 높음
- o 표준오차가 큼 → 표본에 따라 추정계수가 크게 달라질 수 있음
  → 추정의 불확실성이 큼

□ (예) TV 광고 변수의 계수가 $\hat{\beta}_1$ = 0.0475, 표준오차가 0.0027 이라면

o 이는 표본을 반복해서 추출하여 회귀계수를 추정할 경우, $\hat{\beta}_1$의 표본 간 변동 정도가 약 0.0027이라는 의미

□ 그러나 실제 분석에서는 모집단에서 표본을 반복하여 추출할 수 없으며, 일반적으로 하나의 표본만 관측함

□ 따라서 현재 관측된 표본과 회귀모형의 가정을 이용하여 표본분포의 변동성을 추정하며, 이것이 실제 회귀분석 결과에 제시되는 표준오차임

▸ 하나의 표본 → 표본으로부터 표본추출 변동성을 추정 → $SE(\hat{\beta}_j)$

4.1.5.2 신뢰구간

□ 표본자료를 이용하여 모집단의 회귀계수 β_j를 하나의 값 $\hat{\beta}_j$로 추정하는 것을 점 추정(point estimation)이라고 함 (예: $\hat{\beta}_1$=0.0475) : β_j → β_j

□ 그러나 β_j는 표본에 따라 달라질 수 있으므로 하나의 추정값만으로는 추정의 불확실성을 알기 어려움

□ 따라서 하나의 값만 제시하는 대신, 추정값과 표준오차를 이용하여 모집단의 회귀계수 β_j가 위치할 것으로 기대되는 범위를 제시하는데, 이를 신뢰구간(confidence interval)이라고 함

(1) 표준화와 분포

□ 신뢰구간을 구하기 위해 먼저 추정계수 $\hat{\beta}_j$와 모집단의 실제 회귀계수 β_j 사이의 차이를 생각하면: $\hat{\beta}_j - \beta_j$

□ 이 차이가 큰지 작은지를 판단하고자 $\hat{\beta}_j$의 표준오차로 나누어 표준화(standardization)

$$T = \frac{\hat{\beta}_j - \beta_j}{SE(\hat{\beta}_j)}$$

□ 이 통계량은 $\hat{\beta}_j$와 $\hat{\beta}_j$의 차이가 표준오차의 몇 배인가를 나타냄

□ 일반적인 선형회귀모형의 가정이 성립하고 오차항이 정규분포를 따른다고 가정하면, 위의 통계량은 t-분포를 따름

$$T = \frac{\hat{\beta}_j - \beta_j}{SE(\hat{\beta}_j)} \sim t_{df}$$

<참고> 자유도(degrees of freedom)란?

□ t-분포의 모양은 자유도(degrees of freedom, df)에 따라 달라짐

□ 자유도는 통계량을 계산할 때 독립적으로 사용할 수 있는 정보의 수를 의미

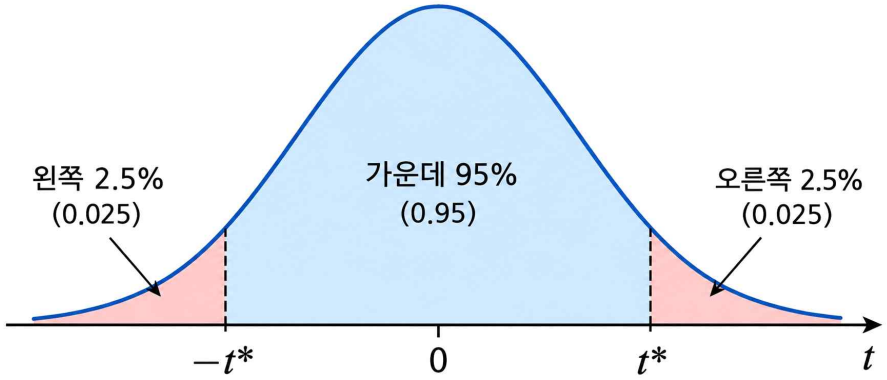
□ 단순선형회귀에서는 n개의 관측자료를 이용하여 두 개의 회귀계수 β_0, β_1를 추정하므로, 잔차의 자유도는 df = n - 2

□ 자유도가 커질수록 t-분포는 표준정규분포에 가까워짐

(2) 95% 신뢰구간의 유도

□ 양측 95% 신뢰구간에서는 t-분포의 양쪽 꼬리에 각각 2.5%의 확률을 두며, 이때의 경계값(임계값)을 $-t^*$와 t^*라고 함

P(T < $-t^*$) = 0.025, P(T > t^*) = 0.025



□ 따라서 $-t^*$와 t^* 사이에 T가 위치할 확률은 95%

$$P(-t^* \leq T \leq t^*) = 0.95$$

□ 여기에 앞의 $T = \frac{\hat{\beta}_j - \beta_j}{SE(\hat{\beta}_j)}$를 대입하면

$$P\left(-t^* \le \frac{\hat{\beta}_j - \beta_j}{SE(\hat{\beta}_j)} \le t^*\right) = 0.95$$

□ 위의 부등식을 β_j에 대해서 정리하면,

$$P(\hat{\beta}_j - t^* SE(\hat{\beta}_j) \le \beta_j \le \hat{\beta}_j + t^* SE(\hat{\beta}_j)) = 0.95$$

□ 따라서 β_j에 대한 95% 신뢰구간은

$$\hat{\beta}_j \pm \ t^* SE(\hat{\beta}_1)$$

(3) 신뢰구간의 계산

□ 회귀계수에 대한 신뢰구간의 기본 형태는: 추정값 ± 임계값 × 표준오차
즉,

$$\hat{\beta}_j \pm \ t^* SE(\hat{\beta}_1)$$

여기서 ▸ $\hat{\beta}_j$: 회귀계수 추정값

▸ $SE(\hat{\beta}_j)$: 추정계수의 표준오차

▸ t^* : 신뢰수준과 자유도에 따라 결정되는 t-분포의 임계값

□ 표본이 충분히 커지면, t-분포는 정규분포에 가까워지므로 95% 신뢰구간의 t^*는 약 1.96에 가까워짐

$$\hat{\beta}_j \pm 1.96\, SE(\hat{\beta}_1)$$

<참고> 신뢰수준과 임계값

□ 큰 표본에서는 각 신뢰수준에 대해 아래 임계값에 근사함

신뢰수준	임계값
90%	1.645
95%	1.960
99%	2.576

(4) 95% 신뢰수준의 의미

□ 95% 신뢰수준이란 동일한 모집단에서 표본을 반복하여 추출하고, 각 표본으로부터 95% 신뢰구간을 구성할 때, 이렇게 만들어진 신뢰구간들 중 약 95%가 모집단의 실제 회귀계수 β_j를 포함한다는 의미

□ 예를 들어 하나의 모집단에서 여러 개의 표본을 반복하여 추출한다고 생각해 보자.

o 첫 번째 표본으로부터 회귀계수 $\hat{\beta}_j^{(1)}$을 추정하고 이를 이용해 첫 번째 표본의 95% 신뢰구간을 계산

o 두 번째 표본으로부터 회귀계수 $\hat{\beta}_j^{(2)}$를 추정하고 이를 이용해 두 번째 표본의 95% 신뢰구간을 계산

o 이와 같이 표본추출을 반복하면 표본마다 $\hat{\beta}_j$가 달라지므로, 각 표본에서 계산되는 신뢰구간도 서로 달라짐

표본 1 → $\hat{\beta}_j^{(1)}$ → 95% 신뢰구간 1

표본 2 → $\hat{\beta}_j^{(2)}$ → 95% 신뢰구간 2

표본 3 → $\hat{\beta}_j^{(3)}$ → 95% 신뢰구간 3

⋮

□ 이렇게 만들어진 신뢰구간들 중에는 모집단의 실제 회귀계수 β_j를 포함하는 구간도 있고, 포함하지 못하는 구간도 있을 수 있음

- 예를 들어 100개의 표본을 추출하여 각각 95% 신뢰구간을 계산한다고 해서 반드시 정확히 95개의 신뢰구간이 β_j를 포함하는 것은 아님
- 어떤 경우에는 93개가 포함할 수도 있고, 다른 경우에는 97개가 포함할 수도 있음
- 그러나 표본추출과 신뢰구간 계산을 매우 많이 반복할수록, 실제 회귀계수 β_j를 포함하는 신뢰구간의 비율은 약 95%에 가까워짐

<주의> 실제로 계산된 하나의 신뢰구간은 어떻게 해석하는가?

□ 실제 회귀분석에서는 위와 같이 수많은 표본을 반복해서 추출하는 것이 아니라, 일반적으로 하나의 표본을 가지고 하나의 신뢰구간을 계산

□ 예를 들어 TV 광고 자료에서 TV 광고비의 회귀계수에 대한 95% 신뢰구간이 다음과 같이 계산되었다고 하자.

95% 신뢰구간 = [0.042, 0.053]

□ 이때 [0.042, 0.053]은 우리가 가지고 있는 하나의 표본자료로부터 실제로 계산한 하나의 신뢰구간임

□ 따라서 이를 "모집단의 실제 회귀계수 β_1이 0.042와 0.053 사이에 있을 확률이 95%이다"로 해석하는 것은 엄밀한 의미에서 옳지 않음

□ 여기서 95%라는 수치는 이번에 계산된 [0.042, 0.053]이라는 특정 구간에 부여된 확률이 아님

□ 95%라는 의미는 같은 방법으로 표본추출과 신뢰구간 계산을 반복한다면, 그렇게 만들어진 신뢰구간들 중 약 95%가 실제 회귀계수 β_j를 포함한다는 뜻임

(5) 신뢰구간의 폭을 결정하는 요인

□ 회귀계수 β_j에 대한 신뢰구간은 다음과 같이 주어짐

$$[\ \hat{\beta}_j - t^* SE(\hat{\beta}_j),\quad \hat{\beta}_j + t^* SE(\hat{\beta}_j)\ ]$$

□ 따라서 신뢰구간의 폭은 상한에서 하한을 뺀 값으로 계산

$$\text{신뢰구간의 폭} = [\ \hat{\beta}_j + t^* SE(\hat{\beta}_j)\ ] - [\ \hat{\beta}_j - t^* SE(\hat{\beta}_j)\ ]$$
$$= 2t^* SE(\hat{\beta}_j)$$

□ 위의 식에서 신뢰구간의 폭은 두 가지 요인에 의해 결정됨

$$\text{신뢰구간의 폭} = 2 \times \underbrace{t^*}_{\text{신뢰수준에 따라 결정}} \times \underbrace{SE(\hat{\beta}_j)}_{\text{추정의 정밀도와 관련}}$$

- 즉, 다른 조건이 동일하다면

$$t^* \uparrow \quad \Rightarrow \text{ 신뢰구간의 폭} \uparrow$$
$$SE(\hat{\beta}_j) \uparrow \quad \Rightarrow \text{ 신뢰구간의 폭} \uparrow$$

① 신뢰수준과 신뢰구간의 폭

□ 먼저 표준오차 $SE(\hat{\beta}_j)$가 동일하다고 가정하면, 신뢰수준이 높아질수록, 더 큰 임계값 t^*를가 필요함

$$\text{신뢰수준}\uparrow \quad \Rightarrow \quad t^*\uparrow \quad \Rightarrow \text{ 신뢰구간의 폭}\uparrow$$

□ 예를 들어 동일한 추정계수와 표준오차를 사용하면, 일반적으로 다음의 관계가 성립

$$\text{90\% 신뢰구간} \subset \text{95\% 신뢰구간} \subset \text{99\% 신뢰구간}$$

□ 따라서 신뢰수준을 높이면, 실제 회귀계수를 포함하도록 설정한 신뢰수준은 높아지지만, 그 대가로 신뢰구간이 넓어짐

→ 즉, 신뢰수준과 신뢰구간의 폭 사이에는 상충관계(trade-off)가 존재

◆ 예:

□ 어떤 회귀계수에 대해 다음과 같은 신뢰구간이 계산되었다고 하자.

95% CI = [0.01, 0.19]

o 이 구간에는 0이 포함되지 않음

□ 그런데 동일한 표본자료에 대해 신뢰수준을 99%로 높이면 더 큰 임계값을 사용하므로 신뢰구간이 넓어질 수 있음

99% CI = [-0.03, 0.23]

o 이 경우에는 넓어진 신뢰구간에 0이 포함됨

◆ 따라서 신뢰수준을 높이는 것은 단순히 “더 좋은 신뢰구간을 얻는다” 는 의미가 아님

□ 신뢰수준이 높아지는 대신 신뢰구간이 넓어져 모집단 회귀계수의 위치를 좁은 범위로 제시하기는 어려워짐

□ 또한 신뢰구간에 0이 포함되는지 여부는 뒤에서 살펴볼 가설검정과 통계적 유의성에 직접 연결됨

② 표준오차와 신뢰구간의 폭

□ 이번에는 신뢰수준을 동일하게 유지한다고 가정

□ 신뢰수준이 같으면 임계값 t^*도 동일하므로, 신뢰구간의 폭은 표준오차 $SE(\hat{\beta}_j)$에 의해 달라짐

□ 표준오차가 작다는 것은 표본이 달라질 때 추정계수 $\hat{\beta}_j$의 변동성이 작다는 의미이므로, 모집단의 회귀계수를 보다 좁은 범위로 추정할 수 있음

$$SE(\hat{\beta}_j)\downarrow \quad \Rightarrow \text{ 신뢰구간의 폭}\downarrow \quad \Rightarrow \text{ 추정의 정밀도}\uparrow$$

□ 반대로 표준오차가 클수록 신뢰구간은 넓어지며, 이는 회귀계수 추정의 불확실성이 크다는 것을 의미

③ 신뢰수준과 정밀도의 구별

"99% 신뢰구간이 95%보다 더 정확한 것 아닌가?"

□ 신뢰수준(confidence level)과 추정의 정밀도(precision)는 서로 다른 개념

- o 신뢰수준을 높임 → t^* 증가 → 신뢰구간이 넓어짐
- o 표준오차가 작아짐 → $SE(\hat{\beta}_j)$ 감소 → 신뢰구간이 좁아짐

⇒ 따라서 [높은 신뢰수준] $\neq$ [높은 정밀도]

□ 예를 들어 99% 신뢰구간은 95% 신뢰구간보다 높은 신뢰수준으로 구성되지만, 일반적으로 구간은 더 넓으므로 회귀계수의 위치를 더 정밀하게 추정했다는 의미는 아님

(6) 가설검정과의 관계

□ 회귀분석에서는 모집단의 회귀계수가 특정한 값을 갖는지에 대해 검정할 수도 있는데, 이를 가설검정(hypothesis testing)이라고 함

□ 특히 설명변수와 반응변수 사이에 선형관계가 존재하는지를 알아보기 위해 다음과 같은 가설을 설정

$$H_0 : \beta_j = 0$$
$$H_1 : \beta_j \neq 0$$

□ $H_0 : \beta_j = 0$은 모집단에서 해당 설명변수와 반응변수 사이에 선형관계가 없다는 가설을 의미

❶ t-통계량

□ 표본으로부터 얻은 $\hat{\beta}_j$가 귀무가설에서 가정한 값 0으로부터 얼마나 떨어져 있는지를 평가하기 위해 t-통계량을 계산

$$t = \frac{\hat{\beta}_j - 0}{SE(\hat{\beta}_j)} = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$$

□ 따라서 t-통계량은 추정계수가 0으로부터 표준오차의 몇 배만큼 떨어져 있는가를 나타냄

4.1.2.5 p 값

□ 앞에서 t-통계량은 추정된 회귀계수 $\hat{\beta}_j$가 귀무가설에서 가정한 값인 0으로부터 표준오차의 몇 배만큼 떨어져 있는지를 나타낸다고 설명

□ 그렇다면 다음으로 생각해 볼 질문은 다음과 같음

"귀무가설이 참이라면, 실제로 계산된 t-값과 같은 정도의 값이 나타날 가능성은 얼마나 되는가?"

o 이를 확률로 나타낸 것이 p값(p-value)

□ p 값은 귀무가설 $H_0 : \beta_j = 0$이 참이라고 가정할 때, 현재 관측된 t-통계량의 절대값과 같거나 그보다 더 큰 값이 나타날 확률을 의미

$$p = P(|T| \geq |t_{obs}| \ |H_0)$$

o 여기서 절대값을 사용하는 이유는 양측검정에서는 양(+)의 방향과 음(-)의 방향을 모두 고려하기 때문

▸ 예를 들어 실제 자료에서 t=2.5가 계산되었다면, t≥2.5인 경우뿐만 아니라 t≤-2.5인 경우도 함께 고려

□ 예를 들어 p값이 0.03이라면, 귀무가설이 참이라고 가정했을 때 |t|가 현재 관측된 값 이상으로 나타날 확률이 약 3%라는 의미

◆ 따라서 p값의 크기는 다음과 같이 해석할 수 있음

■ p값이 작으면 → 귀무가설이 참일 때, 현재와 같은 정도의 t-값이 나타날 가능성이 낮음
→ 따라서 귀무가설에 반하는 증거가 강해짐

■ p값이 크면 → 귀무가설이 참일 때도 현재와 같은 정도의 t-값이 나타날 수 있음
→ 따라서 현재 자료만으로는 귀무가설에 반하는 충분한 증거가 없음

4.1.2.6 통계적 유의수준

□ 앞에서 살펴본 p값은 귀무가설에 반하는 증거가 어느 정도인지를 나타내지만, 실제로 귀무가설을 기각할 것인지를 결정하기 위해서는 판단 기준이 필요

□ 이러한 판단 기준을 유의수준(significance level)이라고 하며, 일반적으로 α로 표시

- o 일반적으로 $\alpha = 0.05$, 즉 5% 유의수준이 널리 사용됨

□ 유의수준은 귀무가설이 실제로 참인데도 이를 잘못 기각할 확률을 어느 정도까지 허용할 것인지를 사전에 정한 기준

- o 예를 들어 $\alpha = 0.05$는 귀무가설이 참인데도 이를 잘못 기각할 확률을 5%로 설정한다는 의미
- o 이처럼 참인 귀무가설을 잘못 기각하는 오류를 제1종 오류(Type I error)라고 함

□ 실제 가설검정에서는 계산된 p값과 유의수준 α 를 비교하여 귀무가설의 기각 여부를 결정

- p값이 유의수준보다 작으면(p< α 이면), 귀무가설을 기각
- p값이 유의수준보다 크거나 같으면(p≥ α 이면), 귀무가설을 기각하지 못함(fail to reject)

o 예를 들어 유의수준을 5%로 정하고 p값이 0.03으로 계산되었다면
p = 0.03 < 0.05 = α 이므로 귀무가설을 기각

□ 회귀분석에서 $H_0 : \beta_j = 0$ 이라는 귀무가설을 기각하면, 해당 설명변수 X_j의 회귀계수는 통계적으로 유의하다(statistically significant)고 표현

o 이는 표본자료가 $\beta_j = 0$이라는 귀무가설에 반하는 충분한 통계적 증거를 제공한다는 뜻

4.1.2.7 추정 결과 해석

□ 앞에서 살펴본 TV 광고 사례의 회귀분석 결과는 다음과 같음

$\hat{\beta}_1$ = 0.0475, $SE(\hat{\beta}_1) \approx$0.0027, t = 17.67, p < 0.001

□ TV 광고비의 회귀계수에 대해 다음의 가설을 검정

$$H_0 : \beta_1 = 0$$
$$H_0 : \beta_1 \neq 0$$

□ TV 변수의 t-통계량은 17.67로, 추정된 회귀계수가 귀무가설에서 가정한 값인 0으로부터 표준오차의 약 17.67배만큼 떨어져 있음을 의미

□ 이에 대응하는 p값은 0.001보다 작음

□ 따라서 일반적으로 사용하는 5% 또는 1% 유의수준에서 p < α 이므로 $H_0 : \beta_1 = 0$을 기각

o 즉, TV 광고비의 회귀계수는 통계적으로 유의함

□ 또한 TV 광고비의 추정계수는 $\hat{\beta}_1$ = 0.0475 이므로, TV 광고비가 1,000달러 증가할 때 판매량은 평균적으로 약 47.5개 증가하는 것으로 추정됨

□ 따라서 TV 광고비와 판매량 사이에는 통계적으로 유의한 양(+)의 선형관계가 존재한다고 해석할 수 있음

□ <주의> 통계적으로 유의한 관계가 존재한다는 사실만으로 TV 광고비 증가가 판매량 증가를 인과적으로 초래했다고 결론 내릴 수는 없음

4.1.2.8 회귀모형의 적합도 평가

◇ 앞에서는 개별 회귀계수 β_j가 통계적으로 유의한지를 살펴보았음

◇ 그러나 회귀분석에서는 개별 회귀계수뿐만 아니라 추정된 회귀모형이 실제 자료에 얼마나 잘 적합되는지도 평가할 필요가 있음

◇ 선형회귀모형의 적합도를 평가하기 위해 대표적으로 잔차표준오차(RSE: residual standard error)와 결정계수(R^2)를 사용

(1) 잔차표준오차 (RSE)

□ 회귀모형에서는 실제 관측값 y_i와 예측값 $\hat{y}_i$사이의 차이를 잔차(residual)라고 함

$$e_i = y_i - \hat{y}_i$$

□ 잔차표준오차(RSE)는 이러한 잔차의 크기를 이용하여 회귀모형의 오차항 ϵ의 표준편차 σ를 추정한 값

$$\text{RSE} = \sqrt{\frac{1}{n-p-1}RSS} = \sqrt{\frac{1}{n-p-1}\sum_{i=1}^{n}(y_i-\hat{y}_i)^2}$$

여기서 ▸RSS: 잔차제곱합, ▸n: 관측치 개수, ▸p: 설명변수 개수

□ 단순선형회귀에서는 설명변수가 하나이므로 p=1

$$\text{RSE} = \sqrt{\frac{1}{n-2}RSS}$$

o n개의 관측 자료로 절편 β_0와 기울기 β_1, 즉 두 개의 회귀계수를 추정하므로 잔차의 자유도는 n−2

◆ RSE의 해석

□ RSE는 관측값들이 추정된 회귀선 주위에서 어느 정도 흩어져 있는지를 나타냄

o RSE가 작음 → 관측값들이 회귀선에 비교적 가까이 위치

o RSE가 큼 → 관측값들이 회귀선으로부터 비교적 많이 떨어져 있음

◆ RSE의 단위

□ RSE는 반응변수 Y와 동일한 단위를 가짐

- o 예를 들어 Y가 매출액이고 단위가 '만원'이라면 RSE의 단위도 '만원'
- o 따라서 RSE를 통해 관측값이 회귀선 주위에서 어느 정도 흩어져 있는지를 반응변수의 실제 단위로 해석할 수 있음

□ 그러나 RSE의 숫자 크기는 반응변수의 측정 단위에 따라 달라짐

- o 동일한 매출자료라도 '원'으로 표시할 때와 '만원'으로 표시할 때 RSE의 숫자는 달라짐
- o 따라서 서로 다른 단위로 측정된 자료의 RSE를 숫자의 크기만으로 직접 비교하기는 어려움
- o 예) 어떤 회귀모형에서 실제 오차의 크기에 해당하는 RSE가 100만원이라고 하자.
  - ▸ 매출액을 '원' 단위로 표시하면, RSE=1,000,000

- 동일한 자료를 '만원' 단위로 표시하면, RSE=100
- 즉, 1,000,000원=100만원이므로 RSE의 숫자는 1,000,000에서 100으로 달라졌지만 실제 오차의 크기는 동일

(2) 결정계수 R^2

□ RSE는 반응변수 Y와 동일한 단위를 가지므로 데이터의 단위나 규모에 따라 값이 달라짐

□ 이에 비해 결정계수(coefficient of determination) R^2는 단위에 영향을 받지 않으며, 반응변수 Y의 전체 변동 가운데 회귀모형이 설명하는 비율을 나타냄

- 먼저 Y의 전체 변동(variance)은

$$\text{TSS(total sum of squares)} = \sum_{i=1}^{n}(y_i - \bar{y}_i)^2$$

- 회귀모형으로 설명되지 않고 남아 있는 변동은

$$\text{RSS(residual sum of squares)}: \sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

- 따라서 TSS - RSS는 회귀모형에 의해 설명된 변동을 나타냄

□ 결정계수는 다음과 같이 정의

$$R^2 = \frac{TSS - RSS}{TSS} = 1 - \frac{RSS}{TSS}$$

▸ 절편을 포함한 일반적인 OLS 회귀모형에서 R^2는 항상 0과 1 사이의 값을 가짐

$$0 \leq R^2 \leq 1$$

◆ R^2에 대한 해석

□ R^2는 반응변수 Y의 전체 변동 중 회귀모형에 의해 설명되는 비율을 뜻함

▸ $R^2 \uparrow$ ⇒ 표본 자료에 대한 적합도(goodness of fit)가 높아짐

▸ $R^2 \downarrow$ ⇒ 표본 자료에 대한 적합도가 낮아짐

□ (예시) TV 광고비만을 설명변수로 사용한 단순회귀모형에서 R^2 = 0.612라면, "매출의 전체 변동의 약 61.2%가 TV 광고비와의 선형관계에 의해 설명된다" 라고 해석

◆ 단순선형회귀에서 R^2와 상관계수의 관계

□ 설명변수가 하나인 단순선형회귀에서는 결정계수 R^2가 X와 Y 사이의 표본상관계수의 r_{XY}제곱과 동일

$$R^2 = r_{XY}^2$$

□ 따라서 단순선형회귀에서는 X와 Y 사이의 선형 상관관계가 강할수록 R^2도 커짐

$$|r_{XY}| \uparrow \quad \Rightarrow \; R^2 \uparrow$$

□ (예시) r_{XY} = 0.8이면, R^2 = $(0.8)^2$ = 0.64 이므로 Y의 변동 중 약 64%가 X와의 선형관계에 의해 설명됨

□ <주의> R^2가 높다고 해서 반드시 좋은 모형이라고 할 수 있는 것은 아님.

R^2는 표본자료에 대한 적합도를 나타내며, 인과관계나 새로운 자료에 대한 예측력을 보장하지 않음

<참고> 퍼센티지 변화와 퍼센티지-포인트 변화

❶ 퍼센티지 변화(the percentage change): 베이스라인(baseline)과 비교한 변화

$$\frac{Y_{final} - Y_{initial}}{Y_{initial}} \times 100$$

❷ 퍼센티지-포인트 변화(the percentage-point change): 비교되는 값들이 퍼센티지(percentage)로 측정되어 있다면 최종값과 최초값 간 차이

$$Y_{final} - Y_{initial}$$ (두 변수 모두 %로 측정됨)

- 예: 유권자 투표율(turnout ratio)이 50%에서 60%로 증가했다면,
  - 퍼센티지 변화는:

$$\frac{60\% - 50\%}{50\%} \times 100 = 20\%$$

  - 퍼센티지-포인트 변화(the percentage-point change)는:

$$60\% - 50\% = 10\, p.p.$$

⇒ 따라서, 우리는 이러한 변화를 (a) 20 *퍼센트* 증가 또는 (b) 10 퍼센트 포인트 증가로 기술할 수 있음