기초 파이썬

2026.9.30일

담당교수: 박진호

서강대학교 경제대학원
2026년 2학기

◈ 오늘의 학습 목표

◈ 이번 데이터 분석에서는 예측(predictions)을 실행

◉ 먼저, 관심 대상인 결과 변수(outcome variable)와 예측 변수(predictor) 간 관계를 그래프에서 하나의 직선(a line)로 요약하는 방법을 학습할 예정

◉ 이어서, 예측 변수의 특정한 값이 주어질 때 이러한 요약 정보를 사용하여 가장 가능성이 높은 결과의 값을 추정할 예정

- 참조:

▸ James, Gareth, Witten, Daniela , Hastie, Trevor , Tibshirani, Robert , Hastie, Trevor(2023), An introduction to statistical learning : with applications in python. 번역판(2024).

▸ 최필선·민인식(2024), (데이터과학의 첫걸음) 빅데이터분석 with Python, 지필미디어.

6.2 다중선형회귀

6.2.1 모형과 추정

□ 단순선형회귀에서는 하나의 설명변수 X를 이용하여 반응변수 Y와의 관계를 분석했지만, 현실에서는 하나의 결과가 여러 요인과 관련되어 있는 경우가 많음

o 예: 매출은 TV뿐 아니라 Radio, Newspaper 등의 광고비와도 관련될 수 있음

□ 이처럼 두 개 이상의 설명변수를 동시에 사용하는 선형회귀모형을 다중선형회귀(multiple linear regression)라 함

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + ... + \beta_p X_{ip} + \epsilon_i$$

- β_j: 절편,
- $\beta_0, \beta_1, ..., \beta_p$: 각 설명변수의 회귀계수,
- ϵ: 모형으로 설명되지 않는 오차항

◆ 회귀계수의 해석

□ 다중선형회귀에서는 각 회귀계수를 해석할 때 다른 설명변수들을 일정하게 유지한다는 조건이 중요

□ β_j는 다른 설명변수들을 고정한 상태에서 X_j가 한 단위 증가할 때 Y가 평균적으로 얼마나 변하는지를 나타냄

o 이를 흔히 "다른 조건이 동일하다면(ceteris paribus)" 이라고 표현

◆ 회귀계수의 추정

□ 모집단의 회귀계수 $\beta_0, \beta_1, ..., \beta_p$는 알 수 없으므로 표본자료를 이용하여 추정

□ OLS를 이용해 다음의 잔차제곱합(RSS)을 최소화하는 회귀계수들($\hat{\beta}_0, \hat{\beta}_1, ..., \hat{\beta}_p$)을 선택

$$\text{RSS} = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

□ 즉, $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + ... + \hat{\beta}_p x_{ip}$를 이용하여 각 관측치의 Y를 예측할 수 있음

6.2.2 회귀모형의 전체적 유의성: F-검정

□ 단순선형회귀에서는 하나의 설명변수만 존재하므로 $H_0 : \beta_1 = 0$을 t-검정하여 설명변수와 반응변수 사이의 선형관계가 존재하는지를 살펴볼 수 있음

□ 다중선형회귀에서는 p개의 설명변수가 존재하므로,

① 각 회귀계수에 대한 t-검정하는 것뿐 아니라,

② 설명변수들을 전체적으로 보았을 때 반응변수와 선형관계가 존재하는가를 검정할 필요가 있음

□ 이를 위해 사용하는 것이 F-검정(F-test)

(1) 가설 설정

□ 다중선형회귀모형의 전체적 유의성에 대한 가설은 다음과 같음

$$H_0 : \beta_1 = \beta_2 = ... = \beta_p = 0$$

$$H_1 : \text{적어도 하나의 } \beta_j \neq 0$$

□ 귀무가설이 참이라면, 모든 설명변수의 기울기 계수가 0이므로 다음이 성립

$$Y_i = \beta_0 + \epsilon_i$$

- o 즉, 설명변수들을 추가하더라도 Y의 변동을 선형적으로 설명하는 데 도움이 되지 않는다는 의미 → 회귀모형은 단순히 평균만을 설명

□ 반면, 대립가설이 참이면, 적어도 하나의 설명변수가 반응변수 Y와 관련이 있음을 의미

(2) F-통계량

◇ 회귀모형에서 반응변수 Y의 전체 변동은 회귀모형이 설명한 부분과 회귀모형이 설명하지 못한 부분(잔차)으로 분해할 수 있음

□ 반응변수 Y의 전체 변동은 관측된 Y 값들이 Y의 평균($\overline{Y}$)을 중심으로 얼마나 흩어져 있는가를 의미

o 즉, 반응변수 Y의 각 관측값이 평균에서 벗어난 정도인 $Y_i - \overline{Y}$에서 출발

□ 그런데 $Y_i - \overline{Y}$는 회귀모형이 설명한 부분 ($\hat{Y}_i - \overline{Y}$)과 회귀모형이 설명하지 못한 부분인 잔차 ($Y_i - \hat{Y}_i$)으로 나뉨

$$Y_i - \overline{Y} = (\hat{Y}_i - \overline{Y}) + (Y_i - \hat{Y}_i)$$

즉, 전체 변동 = 회귀모형이 설명한 변동 + 잔차 변동

◆ F-검정은 ① 회귀모형이 설명한 변동이 ② 회귀모형이 설명하지 못하고 남은 변동(잔차 변동)에 비해 충분히 큰지를 평가하여 모형 전체의 통계적 유의성을 검정하는 방법

□ 이를 제곱합으로 나타내면, Y의 전체 변동(TSS)은 다음과 같이 분해됨

$$TSS = (TSS - RSS) + RSS$$

- o TSS - RSS : 회귀모형이 설명한 변동
- o RSS : 회귀모형이 설명하지 못한 변동

□ 여기서 반응변수 Y의 전체 변동은: $TSS = \sum_{i=1}^{n}(Y_i - \overline{Y}_i)^2$

□ 회귀모형이 설명하지 못하고 남은 잔차 변동은: $RSS = \sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2$

□ 따라서 회귀모형이 설명한 변동은 TSS - RSS

□ 설명된 변동과 잔차 변동은 서로 다른 자유도를 가지므로, 각각을 해당 자유도로 나누어 비교

$$MRS = \frac{TSS - RSS}{p} \text{ : 회귀에 의한 평균제곱}$$

$$MSE = \frac{RSS}{(n-p-1)} \text{ : 잔차 평균제곱}$$

□ 따라서 F-통계량은

$$F = \frac{MSR}{MSE} = \frac{(TSS - RSS)/p}{RSS/(n-p-1)}$$

- n: 관측치의 수,
- p: 설명변수의 수
- 설명된 변동의 자유도: p,
- 잔차 변동의 자유도: (n-p-1)

□ 귀무가설 $H_0 : \beta_1 = \beta_2 = ... = \beta_p = 0$ 이 참이고, 회귀모형의 가정이 성립하면, F-통계량은 아래 분포를 따름

$$F \sim \mathrm{F}_{\mathrm{p},\,\mathrm{n}-\mathrm{p}-1}$$

(3) 해석

□ F-통계량은 회귀모형이 설명한 변동과 잔차 변동을 각각 자유도로 조정한 후 그 상대적인 크기를 나타냄

$$F = \frac{MSR}{MSE}$$

o F가 1에 가까움 → 설명된 변동이 잔차 변동에 비해 특별히 크지 않음

o F가 1보다 더 크게 상승할수록 설명된 변동이 잔차 변동에 비해 상대적으로 크게 됨

□ 따라서 F-통계량이 클수록 귀무가설에 반하는 증거가 강해지는 방향이지만, F-통계량만으로 기각 여부를 결정할 수는 없음

o F 분포는 자유도 (p, n-p-1)에 따라 달라지기 때문

o 따라서 실제 검정에서는 F 통계량에 대응하는 p 값을 이용하여 판단

(4) F-검정의 의사결정

□ 계산된 F 통계량이 F 분포에서 얼마나 큰 값인지를 이용하여 p 값을 계산

$$p = P(F \geq F_{obs} | H_0)$$

□ 유의수준 α 와 p 값을 비교하여 판단

- $p < \alpha \Rightarrow$ 귀무가설(H_0)을 기각
- $p \geq \alpha \Rightarrow$ 귀무가설(H_0)을 기각하지 못함

<참고> F-통계량, F값, F 검정, F-분포

◇ F-통계량은 표본자료로 계산하는 통계량 자체를 말하고, F값은 실제 표본을 넣어서 얻은 그 통계량의 구체적인 숫자를 말함

□ 예를 들어 $F = \frac{(TSS - RSS)/p}{RSS/(n-p-1)}$라고 정의할 때는 F-통계량이고, 실제 계산 결과가 F = 570.3 이라면 "F-통계량의 값은 570.3이다" 또는 간단히 "F값은 570.3이다" 라고 함

◇ 반면 F-검정(F-test)은 F-통계량을 이용해서 귀무가설을 검정하는 전체 절차

□ 즉, F-검정에서 F-통계량을 계산하고, p값으로 판단

◇ 한편, F-분포는 두 분산을 비교할 때 사용되는 분포임. 회귀분석의 F-검정에서도 이러한 원리를 이용하여 회귀모형이 설명하는 변동과 잔차 변동의 상대적인 크기를 평가함

(5) 예: Advertising 데이터 셋 추정 결과

□ TV, Radio, Newspaper 광고비를 동시에 사용하여 Sales를 설명하는 다중선형회귀모형을 추정

$$Sales_i = \beta_0 + \beta_1 TV_i + \beta_2 Radio_i + \beta_3 Newspaper_i + \epsilon_i$$

□ Python을 이용한 추정

```
import statsmodels.formula.api as smf

lm_fit = smf.ols('Sales ~ TV + Radio + Newspaper', data=advertising).fit()

print(lm_fit.summary())
```

OLS Regression Results

Dep. Variable:	Sales	R-squared:	0.897
Model:	OLS	Adj. R-squared:	0.896
Method:	Least Squares	F-statistic:	570.3
Date:	Mon, 06 Apr 2026	Prob (F-statistic):	1.58e-96
Time:	17:15:46	Log-Likelihood:	-386.18
No. Observations:	200	AIC:	780.4
Df Residuals:	196	BIC:	793.6
Df Model:	3		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	2.9389	0.312	9.422	0.000	2.324	3.554
TV	0.0458	0.001	32.809	0.000	0.043	0.049
Radio	0.1885	0.009	21.893	0.000	0.172	0.206
Newspaper	-0.0010	0.006	-0.177	0.860	-0.013	0.011

Omnibus:	60.414	Durbin-Watson:	2.084
Prob(Omnibus):	0.000	Jarque-Bera (JB):	151.241
Skew:	-1.327	Prob(JB):	1.44e-33
Kurtosis:	6.332	Cond. No.	454.

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

□ 회귀모형 전체의 유의성에 대한 가설은

$$H_0 : \beta_1 = \beta_2 = ... = \beta_p = 0$$

$$H_1 : \text{적어도 하나의 } \beta_j \neq 0$$

□ 추정 결과, F-통계량은 약 570으로 나타남: $F \approx 570$

- o 이는 귀무가설하의 $F_{3,\,196}$ 분포에서 매우 큰 값에 해당
- o 이에 대응하는 p값인 Prob(F-statistic)은 0에 가까운 매우 작은 값
- o 따라서 일반적인 유의수준에서 귀무가설 $H_0 : \beta_1 = \beta_2 = ... = \beta_p = 0$을 기각

□ 따라서 TV, Radio, Newspaper의 회귀계수가 모두 0이라고 볼 수 없으며, 적어도 하나의 광고매체는 Sales와 통계적으로 유의한 선형관계를 가짐

<참고> **자유도(degree of freedom)의 개념**

□ 자유도란 통계량을 계산할 때 주어진 제약조건 아래에서 독립적으로 변할 수 있는 정보의 개수를 의미

□ 간단한 예:

- 데이터가 x_1, x_2, x_3 3개이고, 그 평균이 10이라 하자.
- 평균의 정의에 따라 $\frac{x_1+x_2+x_3}{3}=10$이므로 $x_1+x_2+x_3=30$
- 예를 들어 처음 두 값을 $x_1=8,\ x_2=12$로 정하면,
  마지막 값은 $x_3=30-(8+12)$ = 10으로 자동 결정
- 즉, 3개의 값이 있지만 독립적으로 선택할 수 있는 값은 2개임.
- 자유도 = 3 - 1 = 2

□ 일반화

- 데이터가 n개, 표본평균 $\overline{x}$가 주어지면, $\sum_{i=1}^{n}(x_i - \overline{x})$=0 이라는 하나의 제약조건이 존재
- 따라서 n개의 편차 중 n-1개가 정해지면 마지막 하나는 자동으로 결정됨: 자유도=n-1
- [자유도 = 전체 정보의 수 - 추정 또는 제약에 사용된 정보의 수]를 뜻함

□ 표본분산과 자유도

- 표본분산의 계산식: $s^2 = \dfrac{\sum_{i=1}^{n}(x_i - \overline{x})^2}{n-1}$
- 표본으로부터 $\overline{x}$를 추정하면 편차들은 $\sum_{i=1}^{n}(x_i - \overline{x})$ = 0 이라는 제약조건을 만족해야 하므로, n개의 편차 중 독립적으로 변할 수 있는 것은 n-1개임
- 따라서 표본분산을 계산할 때 자유도는 n-1 이 됨

◆ 직관: 평균 하나를 표본에서 추정하면서 자유도 하나를 사용하였다고 이해

☐ 회귀모형과 자유도

- 다중선형회귀모형은 다음과 같이 나타냄: $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + ... + \beta_p X_p + \epsilon$
- 이 모형에서는 절편 β_0 1개, 기울기 계수 $\beta_1, \beta_2, ..., \beta_p$ p개
- 따라서 총 p+1개의 회귀계수를 표본으로부터 추정함

☐ n개의 관측치에서 p+1개의 회귀계수를 추정하므로 잔차의 자유도는 n-(p+1) = n-p-1

☐ F-통계량의 자유도

- F-통계량 계산식: $F = \dfrac{(TSS - RSS)/p}{RSS/(n-p-1)}$
- 분자의 설명된 변동은 p개의 기울기 계수와 관련되므로 분자의 자유도 = p
- 분모의 잔차 변동은 n개의 관측치에서 절편과 p개의 기울기 계수를 추정한 후 남은 변동이므로 분모의 자유도 = n-p-1
- 따라서 귀무가설이 참일 때 F-통계량은 $F \sim \mathrm{F}_{\mathrm{p},\,\mathrm{n}-\mathrm{p}-1}$을 따름
  - 첫 번째 자유도 p: 설명된 변동의 자유도
  - 두 번째 자유도 n-p-1: 잔차 변동의 자유도

◆ Advertising 데이터의 자유도

□ Advertising 데이터에서는 관측치가 n=200, 설명변수가 TV, Radio, Newspaper의 3개이므로 p=3

□ 전체 변동은 표본평균 $\overline{Y}$를 기준으로 계산하므로 자유도는 n-1 = 200-1 = 199

□ 설명된 변동의 자유도는 평균만 설명하는 모형에 추가된 설명변수의 수와 같음

- 평균만 설명하는 모형은 이미 절편 β_0를 포함
- 여기에 TV, Radio, Newspaper를 추가하면 각각의 기울기 계수 $\beta_1, \beta_2, \beta_3$를 추가로 추정
- 따라서 설명된 변동의 자유도는 p=3

□ 전체모형에서는 절편 1개와 기울기 계수 3개, 총 4개의 회귀계수를 추정하므로 잔차의 자유도는 n-p-1 = 200-3-1=196

□ 따라서 전체 변동의 자유도도 다음과 같이 분해됨: 199 = 3+196

즉, $\underbrace{n-1}_{\text{전체 변동}} = \underbrace{p}_{\text{설명된 변동}} + \underbrace{n-p-1}_{\text{잔차 변동}}$

6.2.3 모형 적합도 평가

◇ 다중선형회귀에서도 모형의 적합도는 단순선형회귀와 동일하게 잔차표준오차(RSE)와 결정계수(R^2) 등을 이용하여 평가

(1) 회귀분석 결과의 평가

□ 다중선형회귀에서는 회귀분석 결과를 서로 다른 측면에서 평가할 필요가 있음

- o 개별 회귀계수의 유의성 → t-검정
- o 회귀모형의 전체의 유의성 → F-검정
- o 표본자료에 대한 모형의 적합도 → RSE, R^2

(2) Advertising 데이터 R^2 비교

□ 반응변수를 Sales로 하고 설명변수를 단계적으로 추가하면 다음과 같이 R^2를 비교할 수 있음

회귀모형	설명변수	R^2
단순선형회귀	TV	0.612
다중선형회귀	TV, Radio	약 0.897
다중선형회귀	TV, Radio, Newspaper	약 0.8972

□ TV만 사용한 모형의 R^2는 0.612이므로 Sales 변동의 약 61.2%를 설명

□ Radio를 추가하면 R^2가 약 0.897로 크게 증가

o TV가 이미 포함된 상태에서 Radio를 추가함으로써 Sales 변동에 대한 설명력이 크게 증가

□ 반면 Newspaper를 추가해도 R^2는 거의 증가하지 않음

o TV와 Radio가 이미 포함된 상태에서 Newspaper가 제공하는 추가적인 설명력은 매우 작음

◆ 설명변수를 추가하면 R^2는 어떻게 되는가?

□ OLS 회귀모형에서는 새로운 설명변수를 추가하면 RSS는 감소하거나 그대로 유지됨

□ $R^2 = 1 - \frac{RSS}{TSS}$ 이므로 설명변수를 추가하면, R^2는 증가하거나 그대로 유지되며 감소하지 않음

□ 그러나 R^2이 증가했다고 해서, 새로 추가한 변수가 반드시 유용하다는 의미는 아님

o 설명력이 거의 없는 변수를 추가해도 R^2는 조금 증가할 수 있음

o 따라서 R^2의 증가만으로 새로운 변수의 유용성을 판단하기 어려움

(3) 개별 변수의 유의성과 함께 해석

□ 위의 사항을 고려하면 R^2의 변화뿐 아니라 개별 회귀계수의 t-검정 결과도 함께 살펴볼 필요가 있음

- o Radio: $p < 0.001$ → 다른 광고매체를 통제한 상태에서도 회귀계수가 통계적으로 유의
- o Newspaper: $p \approx 0.86$ → 다른 광고매체를 통제한 상태에서는 회귀계수가 통계적으로 유의하지 않음

□ Advertising 사례에서는 TV에 Radio를 포함하면 모형의 설명력이 크게 증가하지만, TV와 Radio를 고려한 상태에서 추가된 Newspaper가 제공하는 설명력은 매우 작음

4.2.4 예측과 신뢰구간

□ 다중선형회귀모형을 추정하면 새로운 설명변수의 값이 주어졌을 때 반응변수 Y의 값을 예측할 수 있음

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2 + ... + \hat{\beta}_p X_p$$

□ 회귀모형의 예측에는 크게 두 가지 목적이 있음

- o 특정한 설명변수 값에서 평균적인 Y가 얼마인지 추정
- o 특정한 설명변수 값에서 평균적인 Y가 얼마인지 추정

□ 두 경우 모두 표본자료로 추정한 회귀모형을 이용하므로 불확실성이 존재하며, 예측의 목적에 따라 신뢰구간(confidence interval)과 예측구간(prediction interval)을 구분

(1) 평균 반응값에 대한 신뢰구간

□ 회귀모형의 예측값 $\hat{Y}$는 특정한 설명변수 값이 주어질 때 평균적인 반응값을 추정한 값

o 예: TV=100, Radio=20 인 경우(단위: 천달러)

$$\widehat{Sales} = \hat{\beta}_0 + \hat{\beta}_1(100) + \hat{\beta}_2(20)$$

o 이는 “TV 광고비가 10만 달러, Radio 광고비가 2만 달러인 경우 평균 판매량은 얼마인가?” 에 해당

□ 그러나 $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2$는 표본자료에서 추정한 회귀계수이므로, 이를 이용해 계산한 평균 판매량에도 추정의 불확실성이 존재

□ 이러한 평균 반응값의 추정 불확실성을 구간으로 나타낸 것이 신뢰구간

(2) Advertising 데이터 예

□ TV 광고비가 10만 달러, 라디오 광고비가 2만 달러일 때 평균 판매량에 대한 95% 신뢰구간이 [10,985, 11,528] 이라고 하자.

o 동일한 방법으로 표본추출과 신뢰구간의 구성을 반복하면, 이렇게 만들어진 구간 중 약 95%가 해당 조건에서의 실제 평균 판매량을 포함

(3) 신뢰구간과 예측구간의 차이

□ 평균 판매량이 아니라 동일한 광고비를 지출한 개별 사례의 판매량을 예측하려면, 예측구간(prediction interval)을 사용

- o 신뢰구간 → 평균적인 Y의 범위: 이런 광고비를 사용하는 기업들의 평균 판매량은?
- o 예측구간 → 개별 Y의 범위: 이런 광고비를 사용하는 특정 기업의 판매량은

□ 개별 관측값에는 평균 반응값의 추정 불확실성뿐만 아니라 개별적인 오차 ϵ도 존재하므로 "예측구간은 신뢰구간보다 일반적으로 더 넓음"

4.3 회귀 모형의 기타 사항

4.3.1 정성적 예측변수

□ 지금까지는 소득, 광고비, 연령과 같이 숫자의 크기에 의미가 있는 정량적 변수(quantitative variable)를 주로 설명변수로 사용

□ 실제 자료에는 성별, 학생 여부, 결혼 여부와 같이 여러 번주로 구분되는 정성적 변수(qualitative variable) 또는 범주형 변수(categorical variable)도 존재

□ 범주형 변수도 더미변수(dummy variable)로 나타내어 선형회귀모형의 설명변수로 사용할 수 있음

◆ Credit 데이터

□ Credit 데이터는 개인의 평균 신용카드 미상환 잔액(Balance, 달러)과 개인 특성에 관한 자료

o 정량적 변수: Balance, Age, Cards(신용카드 개수), Education(교육 연수), Income(소득, 천 달러), Limit(신용한도), Rating(신용등급)

o 정성적 변수: Gender(성별), Student(학생 여부), Married(결혼 여부), Ethnicity(인종)

❶ 데이터 불러오기

```
import pandas as pd
import statsmodels.formula.api as smf

url = ('https://raw.githubusercontent.com/JWarmenhoven/'
       'ISLR-python/master/Notebooks/Data/Credit.csv')

Credit = pd.read_csv(url, usecols=list(range(1,12)))

# 문자열 앞뒤의 불필요한 공백 제거
Credit["Gender"] = Credit["Gender"].str.strip()
Credit["Ethnicity"] = Credit["Ethnicity"].str.strip()

Credit.head()
```

	Income	Limit	Rating	Cards	Age	Education	Gender	Student	Married	Ethnicity	Balance	Student2
0	14.891	3606	283	2	34	11	Male	No	Yes	Caucasian	333	0
1	106.025	6645	483	3	82	15	Female	Yes	Yes	Asian	903	1
2	104.593	7075	514	4	71	11	Male	No	No	Asian	580	0
3	148.924	9504	681	3	36	11	Female	No	No	Asian	964	0
4	55.882	4897	357	2	68	16	Male	No	Yes	Caucasian	331	0

(1) 범주가 2개인 경우

□ 범주형 설명변수가 두 개의 범주를 가지는 경우, 하나의 범주를 기준범주(reference category)로 정하고 다른 범주를 나타내는 하나의 더미변수를 생성

o 예를 들어 Gender에서 Male을 기준범주로 하면

$$D_i = \begin{cases} 1, & \text{if } Female \\ 0, & \text{if } Male \end{cases}$$

□ Gender만을 설명변수로 사용하는 회귀모형은

$$Balance_i = \beta_0 + \beta_1 D_i + \epsilon_i$$

◆ 더미변수 회귀계수의 해석

□ Male은 $D_i = 0$이므로 $E(Balance|Male) = \beta_0$

□ Female은 $D_i = 1$이므로 $E(Balance|Female) = \beta_0 + \beta_1$

□ 따라서 β_0 = Male의 평균 Balance, β_1 = Female의 평균 Balance - Male의 평균 Balance

o 즉, 더미변수의 회귀계수는 기준범주와 비교범주의 평균 차이를 나타냄

◆ Python을 이용한 추정

□ statsmodels의 formula 방식을 사용하면 사용자가 더미변수를 직접 생성하지 않고 범주형 변수를 회귀식에 사용할 수 있음

□ 다음에서는 Male을 기준범주로 명확하게 지정하여 추정

```
est = smf.ols('Balance ~ C(Gender, Treatment(reference="Male"))', data=Credit).fit()

print(est.summary().tables[1])
```

```
==============================================================================================
                                                 coef    std err          t      P>|t|      [0.025      0.975]
----------------------------------------------------------------------------------------------
Intercept                                    509.8031     33.128     15.389      0.000     444.675     574.931
C(Gender, Treatment(reference="Male"))[T.Female]  19.7331     46.051      0.429      0.669     -70.801     110.267
==============================================================================================
```

□ 코드 설명:

- C(Gender, ⋯) : Gender를 범주형 변수로 처리
- Treatment(reference="Male") : Male을 기준범주로 지정
- [T.Female] : 기준범주 Male과 비교되는 Female 범주를 의미. T는 Treatment coding 의미
- .tables[1]: 회귀분석 결과 중 회귀계수, 표준오차, t-통계량, p-value, 신뢰구간이 포함된 표를 출력

◆ 추정 결과의 해석

□ 절편은 $\hat{\beta}_0$ = 509.80 이므로 Male의 평균 Balance는 약 509.80달러

□ Female의 회귀계수는 $\hat{\beta}_1$ = 19.73 이므로 Female의 평균 Balance는 Male보다 약 19.73달러 높음

⇒ 따라서 Female의 평균 Balance는 509.80 + 19.73 = 529.53 달러

□ Gender 계수의 p 값은 0.669 이므로 $H_0 : \beta_1 = 0$을 유의수준 5%에서 기각하지 못함

⇒ Male과 Female의 평균 Balance가 다르다고 판단할 충분한 통계적 증거가 없음

◆ <참고> 기준범주를 바꾸면?

□ Female을 기준범주로 지정하면

```
est2 = smf.ols( 'Balance ~ C(Gender, Treatment(reference="Female"))', data=Credit ).fit()

print(est2.summary().tables[1])
```

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	529.5362	31.988	16.554	0	466.649	592.423
C(Gender, Treatment(reference="Female"))[T.Male]	-19.7331	46.051	-0.429	0.669	-110.267	‘70.801

□ 추정계수는 β_0 = 529.53, β_1 = -19.73 으로 바뀜

- o 절편: Female의 평균 Balance
- o Male의 계수: Male의 평균 – Female의 평균

⇒ 기준범주가 바뀌면, 절편과 더미변수 계수의 해석 및 부호는 달라지지만, 각 집단의 평균 또는 두 집단 간 실제 차이는 변하지 않음

(2) 범주가 3개 이상인 경우

□ 범주가 3개인 경우에는 하나의 범주를 기준범주로 하고 2개의 더미변수를 사용

□ 예를 들어 Ethnicity에는 African American, Asian, Caucasian의 세 범주가 있음

□ African American을 기준범주로 하면 다음 두 개의 더미변수를 생성

$$D_{1i} = \begin{cases} 1, & Asian \\ 0, & \text{그 외} \end{cases}, \qquad D_{2i} = \begin{cases} 1, & Caucasian \\ 0, & \text{그 외} \end{cases}$$

□ 회귀모형은

$$Balance_i = \beta_0 + \beta_1 D_{1i} + \beta_2 D_{2i} + \epsilon_i$$

- o β_0: 아프리카계 미국인의 평균 Balance

  β_1: 아시아계와 아프리카계 미국인 간 평균 Balance 차이

  β_2: 백인과 아프리카계 미국인 간 평균 Balance 차이

◆ Python을 이용한 추정

□ Ethnicity 변수의 경우 아프리카계 미국인(African American)을 기준범주로 하면

```
est = smf.ols('Balance ~ C(Ethnicity, Treatment(reference="African American"))', data=Credit).fit()

print(est.summary().tables[1])
```

□ 주요 추정결과는

```
==============================================
                 coef    std err      t      P>|t|
----------------------------------------------
Intercept      531.0000   46.319   11.464   0.000
Asian          -18.6863   65.021   -0.287   0.774
Caucasian      -12.5025   56.681   -0.221   0.826
==============================================
```

□ 기준범주인 African American의 평균 Balance는 531.00 달러

□ Asian의 평균 Balance는 531.00-18.69 = 512.31 달러

□ Caucasian의 평균 Balance는 531.00 – 12.50 = 518.50 달러

□ Asian과 Caucasian의 회귀계수에 대한 p 값은 각각 0.774와 0.826

⇒ 두 집단 모두 기준집단인 African American과 평균 Balance가 다르다고 판단할 충분한 통계적 증거가 없음

<참고> 위의 p 값은 각각의 범주를 기준범주와 비교하는 개별 t-검정의 결과임.

Ethnicity 전체의 통계적 유의성을 판단하려면
$H_0 : \beta_1 = \beta_2 = 0$에 대한 F-검정을 이용

(3) 더미변수 개수 및 기준범주

□ 범주형 변수가 K 개 범주를 가지면, 절편을 포함하는 회귀모형에서는 일반적으로 K-1 개의 더미변수를 사용

- o Gender 변수: 2개 범주에서 Female 더미변수 1개를 사용
- o Ethnicity 변수: 3개 범주에서 더미변수 2개(Asian과 Caucasian)를 생성

□ 더미변수로 만들지 않은 하나의 범주가 기준범주가 되며, 각 더미변수의 회귀계수는 기준범주와의 차이를 나타냄

□ 모든 범주에 대해 더미변수를 만들 필요가 없는 이유는 하나의 범주에 대한 정보가 나머지 더미변수들로부터 이미 결정되기 때문

- o 예를 들어 Gender의 경우 $D_{Male} + D_{Female} = 1$ 이므로 Male 여부를 알고 있으면 Female 여부도 자동으로 결정됨

◆ <추가> 범주형 변수 자동 처리

□ statsmodels의 formula 방식을 이용하면 Ethnicity를 직접 설명변수로 입력할 수 있으며, Python은 범주형 변수에 필요한 더미변수를 자동으로 생성하여 회귀모형을 추정

```
est3 = smf.ols('Balance ~ Ethnicity', Credit).fit()
print(est.summary().tables[1])
```

```
==========================================================================
                    coef    std err          t      P>|t|      [0.025      0.975]
--------------------------------------------------------------------------
Intercept          531.0000     46.319     11.464      0.000     439.939     622.061
Ethnicity[T.Asian]  -18.6863     65.021     -0.287      0.774    -146.515     109.142
Ethnicity[T.Caucasian]  -12.5025     56.681     -0.221      0.826    -123.935      98.930
==========================================================================
```

□ 위에서 African American이 기준범주가 되고, 나머지 두 범주에 대한 더미변수가 생성됨

- o Ethnicity[T.Asian]: Asian과 African American의 평균 Balance 차이
- o Ethnicity[T.Caucasian]: Caucasian과 African American의 평균 Balance 차이

◈ 기준 범주: African American (계수 표에 이름이 없는 집단)

- 알파벳 순서대로 African American이 A로 시작해서 가장 빨라 자동으로 기준(0)이 됨

□ 추정결과를 이용하면 각 집단의 평균 Balance는 다음과 같음

- o African American : 531.00
- o Asian : 531.00 - 18.68 = 512.32
- o Caucasian : 531.00 - 12.50 = 518.50

□ 개별 회귀계수의 통계적 유의성을 살펴보면

- o Asian: t = -0.287, p = 0.774
- o Caucasian: t = -0.221, p = 0.826

□ 두 경우 모두 p > 0.05이므로, 각 집단의 평균 Balance가 기준집단인 African American과 다르다고 판단할 충분한 통계적 증거가 없음

◇ 위의 p 값은 Asian과 Caucasian을 각각 African American과 비교하는 개별 t-검정의 결과임. Ethnicity 변수 전체의 유의성을 판단하려면 두 회귀계수가 동시에 0인지에 대한 F-검정이 필요

4.4 상호작용 항

(1) 상호작용의 개념

□ 지금까지의 다중선형회귀모형에서는 각 설명변수의 효과가 다른 설명변수의 값과 관계없이 일정하다고 가정

□ 예: Advertising 데이터를 사용한 다중선형회귀 모형에서

β_1 : Radio 광고비를 일정하게 유지한 상태에서 TV 광고비가 1단위 증가할 때 Sales가 평균적으로 얼마나 변하는지를 나타냄

β_2 : TV 광고비를 일정하게 유지한 상태에서 Radio 광고비가 1단위 증가할 때 Sales가 평균적으로 얼마나 변하는지를 나타냄

□ 그러나 실제로는 두 광고매체를 함께 사용할 때 시너지(synergy)가 발생할 수 있음

o 예를 들어 Radio 광고를 많이 할수록 TV 광고의 효과가 더 커질 수 있음

o 이처럼 한 설명변수가 Y에 미치는 관계가 다른 설명변수의 값에 따라 달라지는 것을 상호작용(interaction)이라고 함

(2) 상호작용 항을 포함한 회귀모형

◇ 두 개의 예측변수가 있는 선형회귀모형을 고려

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$$

o 이 모형에서는 X_2의 값에 관계없이, X_1을 한 단위 증가시키면, Y는 평균 β_1 단위 증가

o 상호작용 효과를 고려하기 위해서 X_1과 X_2의 곱을 세 번째 예측변수에 포함

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + \epsilon$$

$$\begin{aligned} Y &= \beta_0 + (\beta_1 + \beta_3 X_2) X_1 + \beta_2 X_2 + \epsilon \\ &= \beta_0 + \hat{\beta}_1 X_1 + \beta_2 X_2 + \epsilon \end{aligned}$$

여기서 $\hat{\beta}_1 = (\beta_1 + \beta_3 X_2)$

$\hat{\beta}_1$은 X_2의 값에 따라 바뀌므로 X_1이 Y에 미치는 영향은 일정하지 않고, X_2가 변함에 따라 X_1이 Y에 미치는 영향이 달라짐

◇ TV와 Radio 사이의 상호작용을 고려하기 위해 두 변수의 곱인 TV×Radio를 회귀모형에 포함

$$Sales = \beta_0 + \beta_1 TV + \beta_2 Radio + \beta_3 (TV \times Radio) + \epsilon$$

□ 이 식을 TV의 관점에서 정리하면

$$Sales = \beta_0 + \beta_2 Radio + (\beta_1 + \beta_3 Radio) TV + \epsilon$$

□ 따라서 TV가 Sales에 미치는 관계는 $\beta_1 + \beta_3 Radio$가 됨

□ 즉, TV의 효과가 일정한 것이 아니라 Radio 광고비의 크기에 따라 달라짐

- o $\beta_3 > 0$: Radio가 많을수록 TV의 효과가 커짐
- o $\beta_3 < 0$: Radio가 많을수록 TV의 효과가 작아짐
- o $\beta_3 = 0$: TV의 효과가 Radio와 관계없이 일정

(3) 상호작용 항 추정

□ statsmodels에서는 TV:Radio를 이용하여 두 변수의 상호작용 항을 모형에 포함할 수 있음

```
est = smf.ols('Sales ~ TV + Radio + TV:Radio', advertising).fit()
print(est.summary().tables[1])
```

	coef	std err	t	P&|t|	[0.025	0.975]
Intercept	6.7502	0.248	27.233	0.000	6.261	7.239
TV	0.0191	0.002	12.699	0.000	0.016	0.022
Radio	0.0289	0.009	3.241	0.001	0.011	0.046
TV:Radio	0.0011	5.24e-05	20.727	0.000	0.001	0.001

□ 따라서 추정된 회귀식은

$$\widehat{Sales} = 6.7502 + 0.0191\,TV + 0.0289\,Radio + 0.0011\,(TV \times Radio)$$

(4) 상호작용 항의 해석

□ TV 광고비가 Sales에 미치는 관계는 0.0191 + 0.0011 Radio 이므로 Radio 광고비가 증가할 수록 TV 광고와 Sales 간의 관계가 커짐

o 예를 들어, Radio = 0 인 경우 ⇒ TV의 효과 = 0.0191

Radio = 20 인 경우 ⇒ TV의 효과 = 0.0191 + 0.0011 (20) = 0.0411

□ 상호작용 항 TV × Radio 변수의 p 값이 매우 작으므로(0에 가까움) $H_0 : \beta_3 = 0$을 기각

⇒ TV와 Sales의 관계가 Radio 광고비의 수준에 따라 달라진다는 통계적 증거가 있음

◇ 상호작용 항에서 주의할 점

□ 상호작용 항이 포함되면 TV의 계수 0.0191을 단순히 TV 광고비가 1단위 증가할 때 Sales가 0.0191 증가한다고 해석하면 안 됨

TV의 효과 = 0.0191 + 0.0011 Radio 이기 때문

5. 다항식 회귀

◇ 반응변수 Y와 설명변수 X 간 관계가 직선으로 충분히 설명되지 않는 경우 다항식 회귀 (polynomial regression)를 이용하여 비선형 관계를 추정할 수 있음

□ 예를 들어 단순선형회귀모형은 아래와 같이 X와 Y의 관계를 하나의 직선으로 나타냄

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

□ 그러나 실제 자료에서는 X가 증가함에 따라 Y의 변화 정도가 달라지는 비선형 관계 (nonlinear relationship)가 나타날 수 있음

□ 이러한 경우 $X^2, X^3, \cdots$과 같은 항을 추가하여 곡선 형태의 관계를 추정할 수 있음

(1) Auto 데이터셋

□ Auto 데이터는 자동차의 연비와 자동차 특성에 관한 자료로 주요 변수는 다음과 같음

- mpg: 연비(miles per gallon)
- cylinders: 실린더 개수
- displacement: 엔진 배기량
- horsepower: 엔진 마력
- weight: 차량 무게(파운드)
- acceleration: 가속 시간(초)
- year: 모델 연식
- origin: 자동차 제조 지역(1 미국, 2 유럽, 3 일본)
- name: 자동차 이름

□ 여기에서는 자동차의 마력(horsepower)과 연비(mpg) 간 관계를 분석

```
import pandas as pd

Auto = pd.read_csv( r'D:\서강대\Auto.csv', na_values=['?'] )

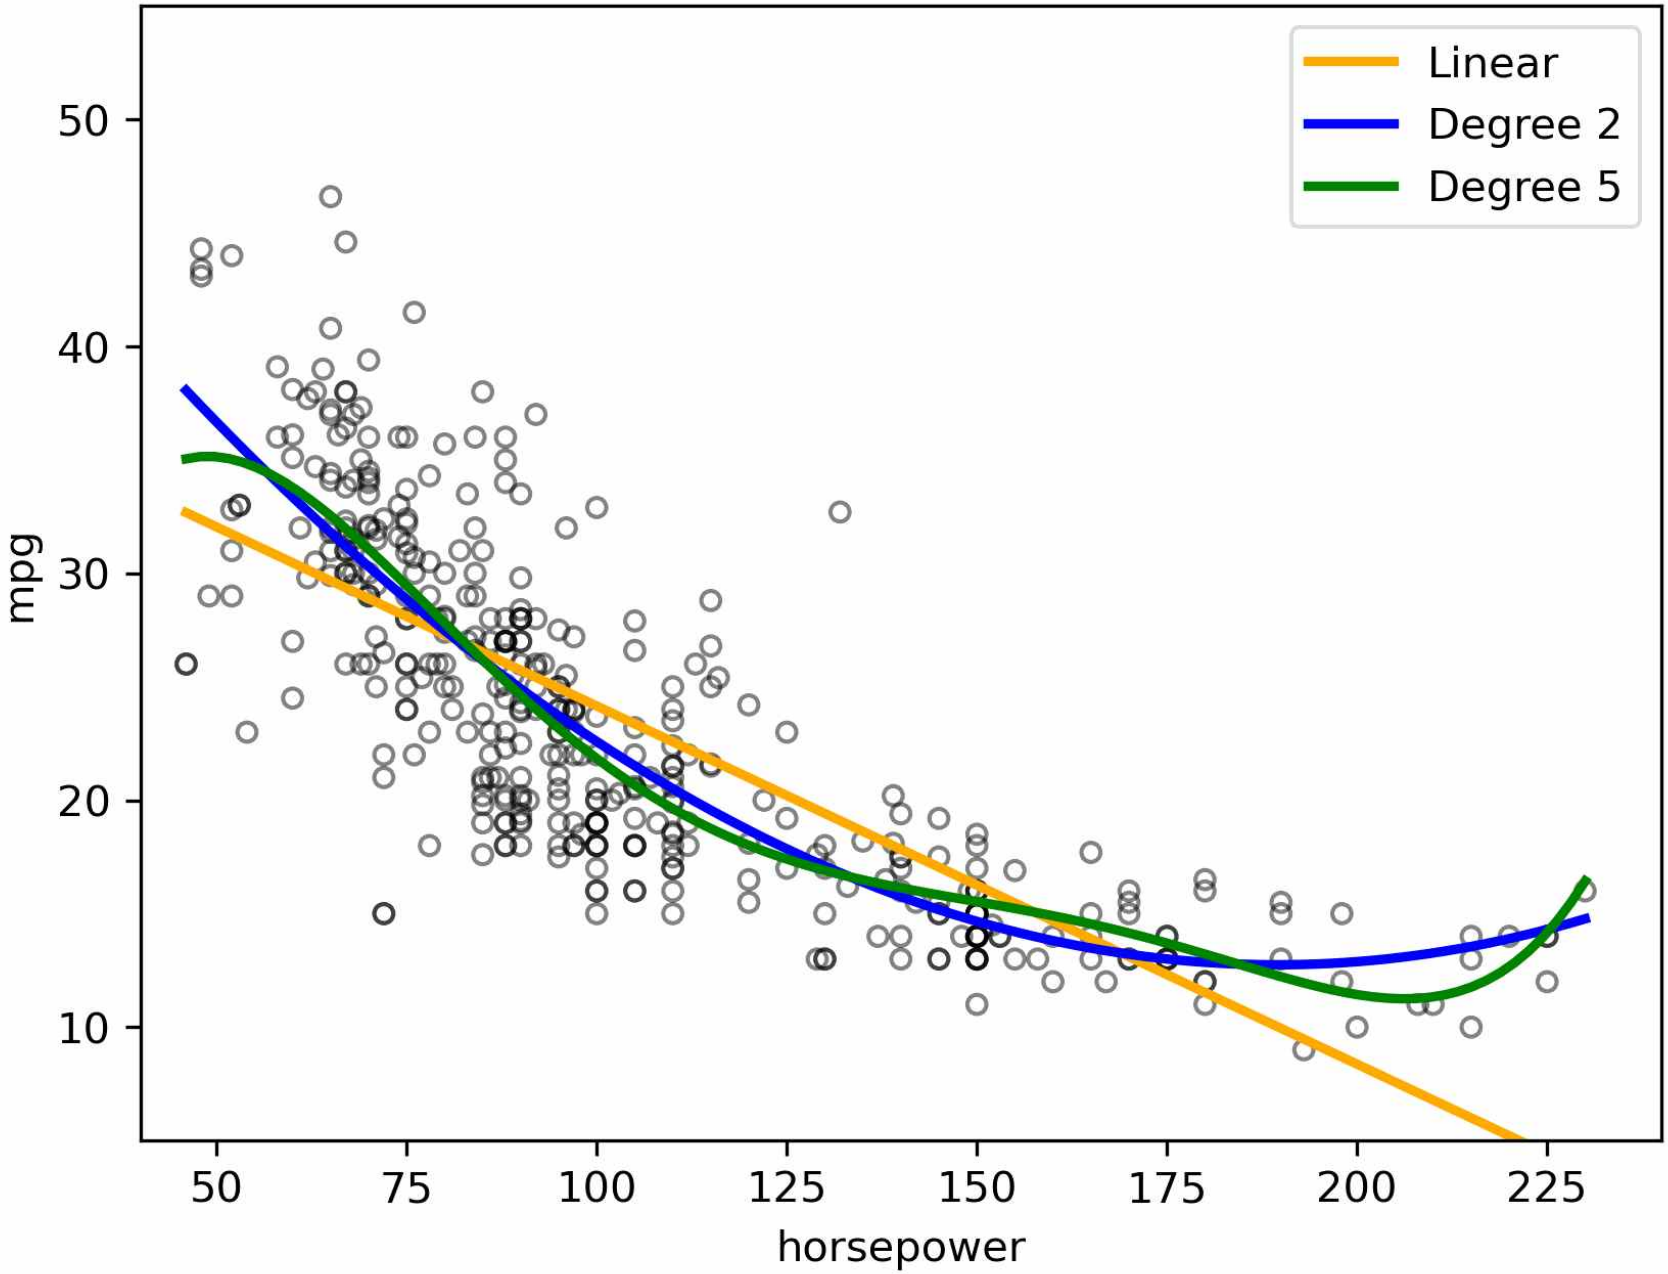
Auto = Auto.dropna()
Auto.head()
```

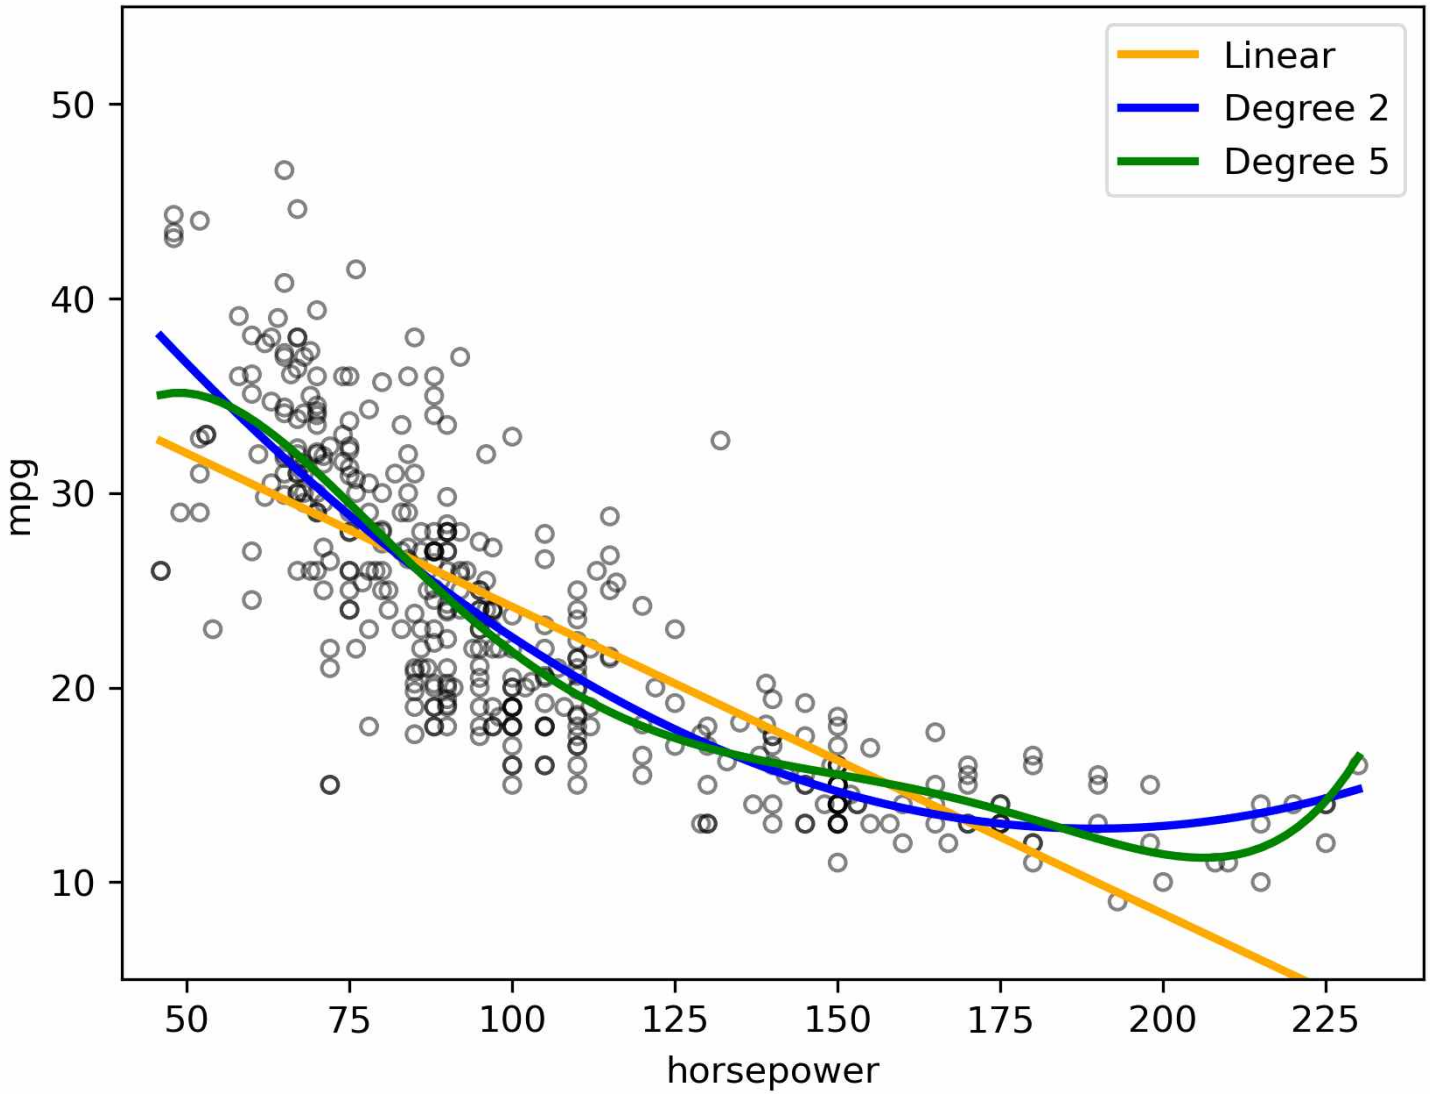
	mpg	cylinders	displacement	horsepower	weight	acceleration	year	origin	name
0	18.0	8	307.0	130.0	3504	12.0	70	1	chevrolet chevelle malibu
1	15.0	8	350.0	165.0	3693	11.5	70	1	buick skylark 320
2	18.0	8	318.0	150.0	3436	11.0	70	1	plymouth satellite
3	16.0	8	304.0	150.0	3433	12.0	70	1	amc rebel sst
4	17.0	8	302.0	140.0	3449	10.5	70	1	ford torino

(2) 선형관계와 비선형관계

□ 먼저 horsepower와 mpg의 관계를 산점도로 살펴보면, 마력이 증가할수록 연비가 낮아지는 경향이 나타남

□ 그러나 두 변수의 관계가 완전한 직선이라기보다는 곡선 형태의 비선형 관계를 보임


Linear
Degree 2
Degree 5
mpg
horsepower
50
40
30
20
10
50
75
100
125
150
175
200
225



▸ 오렌지색 선: 선형 회귀 추정을 의미

▸ mpg와 horsepower 사이에는 뚜렷한 관계가 있으나, 비선형 관계를 시사

□ 선형회귀모형에서는

$$mpg_i = \beta_0 + \beta_1 \times horsepower + \epsilon$$

이므로 horsepower가 1단위 증가할 때 mpg의 변화가 항상 β_1로 일정하다고 가정

□ 이러한 제약을 완화하기 위해 horsepower의 제곱 항을 추가

$$mpg_i = \beta_0 + \beta_1 \times horsepower + \beta_2 \times horsepower^2 + \epsilon$$

□ $horsepower^2$가 추가되면 horsepower와 mpg의 관계를 직선이 아니라 곡선으로 표현할 수 있음

◆ 왜 이것도 선형회귀모형인가?

□ $horsepower^2$가 포함되어 있으므로 설명변수와 반응변수의 관계는 비선형

□ 그러나 회귀계수 $\beta_0, \beta_1, \beta_2$는 모두 1차로 결합되어 있음

□ 위 식을 $mpg_i = \beta_0 + \beta_1 \times X_{1i} + \beta_2 X_{2i} + \epsilon$라고 생각하면

$X_1 = horsepower,\ X_2 = horsepower^2$인 다중선형회귀모형과 동일한 형태

□ 따라서 다항식 회귀는 설명변수와 Y의 관계는 비선형일 수 있지만, 회귀계수에 대해서는 선형인 회귀모형임

(3) 2차 다항식 회귀 추정

□ 가장 간단한 방법은 I()를 이용하여 회귀식 안에서 직접 제곱항을 생성하는 것

```
import statsmodels.formula.api as smf

model = smf.ols( 'mpg ~ horsepower + I(horsepower**2)', data=Auto ).fit()

print(model.summary().tables[1])
```

```
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept     56.9001      1.800     31.604      0.000      53.360      60.440
horsepower    -0.4662      0.031    -14.978      0.000      -0.527      -0.405
I(horsepower ** 2)     0.0012      0.000     10.080      0.000       0.001       0.001
==============================================================================
```

□ I(horsepower**2)는 horsepower의 제곱을 계산하여 새로운 설명변수로 사용한다는 의미

<추가>

◇ 별도의 변수를 먼저 만들어도 동일하게 추정할 수 있음

```
Auto[“horsepower2“] = Auto[“horsepower“]**2

model = smf.ols( ’mpg ~ horsepower + horsepower2’, data=Auto ).fit()
```

◇ 2차항을 추가한 모형 추정 방법: np.power()를 사용

```
import numpy as np

# np.power(값, 지수) 형태로 사용
model = smf.ols(’mpg ~ horsepower + np.power(horsepower, 2)’, data=Auto).fit()

print(model.summary().tables[1])
```

(4) 추정 결과

◇ 2차 다항식 회귀모형의 주요 추정결과는 다음과 같음

$$\widehat{mpg} = 56.9001 - 0.4662\, horsepower + 0.0012\, horsepower^2$$

□ $horsepower^2$의 계수에 대한 p 값이 매우 작으므로 $H_0 : \beta_2 = 0$을 기각

⇒ horsepower와 mpg 간 관계에 비선형적인 부분이 존재한다는 통계적 증거가 있음

□ 또한 R^2는 선형모형 0.606에서 2차 다항식모형 0.688로 증가해 표본 내 적합도가 개선됨

(5) 다항식의 차수를 높이면 항상 좋은가?

□ 그렇다면 X^2뿐만 아니라 $X^3, X^4, X^5, \cdots$ 을 계속 추가하면 모형이 더욱 좋아질까?

□ 다항식의 차수를 높이면 자료에 보다 유연하게 적합할 수 있음

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \ldots + \beta_p X^p + \epsilon$$

□ 그러나 차수가 지나치게 높아지면 표본자료의 작은 변화까지 따라가면서 회귀곡선에 불필요한 굴곡이 나타날 수 있음

□ 따라서 다항식의 차수를 높이는 것이 항상 더 좋은 모형을 의미하지는 않음

- o 이것은 앞에서 배운 모형의 유연성(flexibility)과 과적합(overfitting) 문제와 연결됨
- o 차수 증가 → 모형의 유연성 증가 → 표본 적합도 개선 가능 → 과적합 가능성도 증가

6. 상관관계

◇ 상관계수(correlation)는 두 변수 사이의 선형 관계의 방향과 강도를 하나의 숫자로 나타내는 지표

o 일반적으로 상관계수라고 하면 피어슨 상관계수(Pearson correlation coefficient)를 말함

□ 산점도가 두 변수의 관계를 시각적으로 보여준다면, 상관계수는 그 관계를 하나의 숫자로 요약

$$-1 \leq r \leq 1$$

o 여기서 r은 표본에서 계산한 상관계수를 나타냄

6.1 상관계수의 해석

□ 상관계수는 두 변수 간 선형 관계의 두 가지 특성을 나타냄

① 방향(direction) : 상관계수의 부호
② 강도(strength) : 상관계수의 절대값

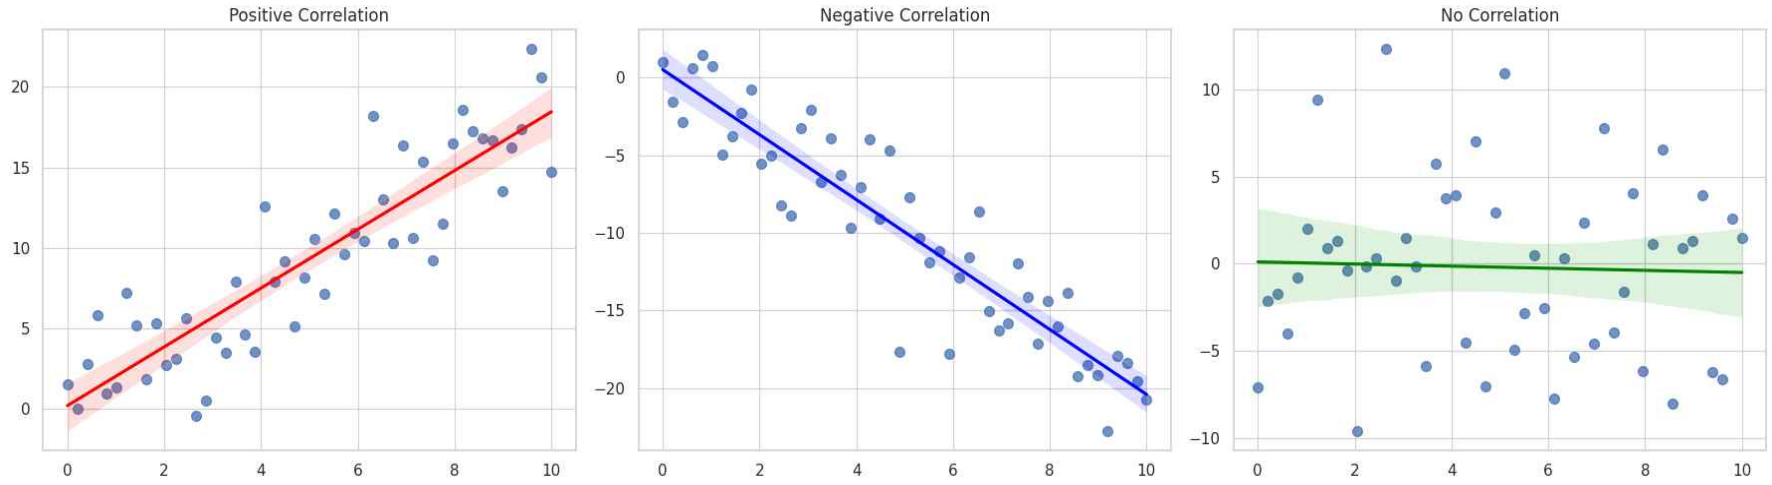
(1) 선형 관계의 방향

□ r > 0 : 양(+)의 상관관계

- o X가 큰 관측값에서 Y도 큰 경향
- o X가 작은 관측값에서 Y도 작은 경향

→ 산점도가 대체로 우상향

□ 따라서 상관계수의 부호(sign)는 두 변수 사이의 선형관계가 어느 방향인지를 나타냄



⑵ 선형 관계의 강도

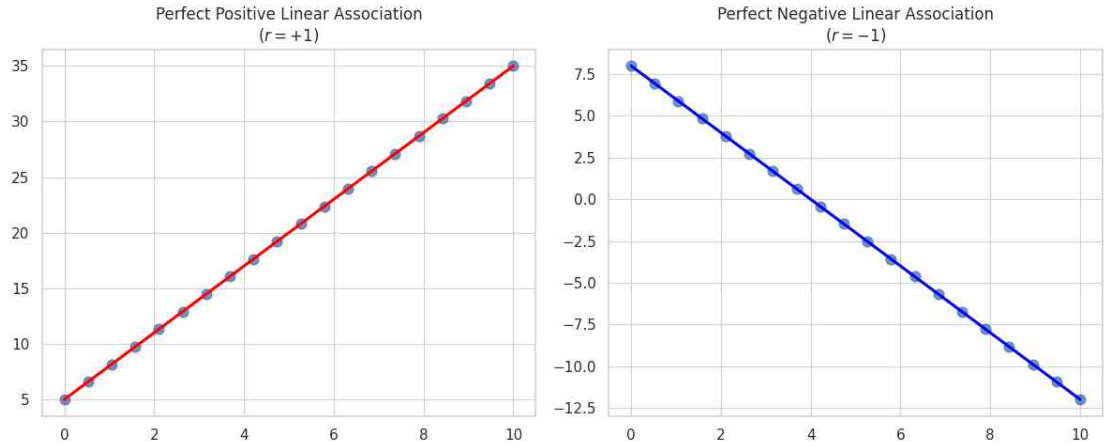
□ 상관계수의 절대값 $|r|$은 두 변수 사이의 선형관계가 얼마나 강한지를 나타냄

① 극단적인 경우의 하나로, **두 변수 간 선형 관계가 존재하지 않을 때는** 상관계수의 절대값이 0에 근접

▸위 그림에서 오른쪽. 이때는 데이터를 적절하게 요약하는 직선을 적합하는 것이 어려움

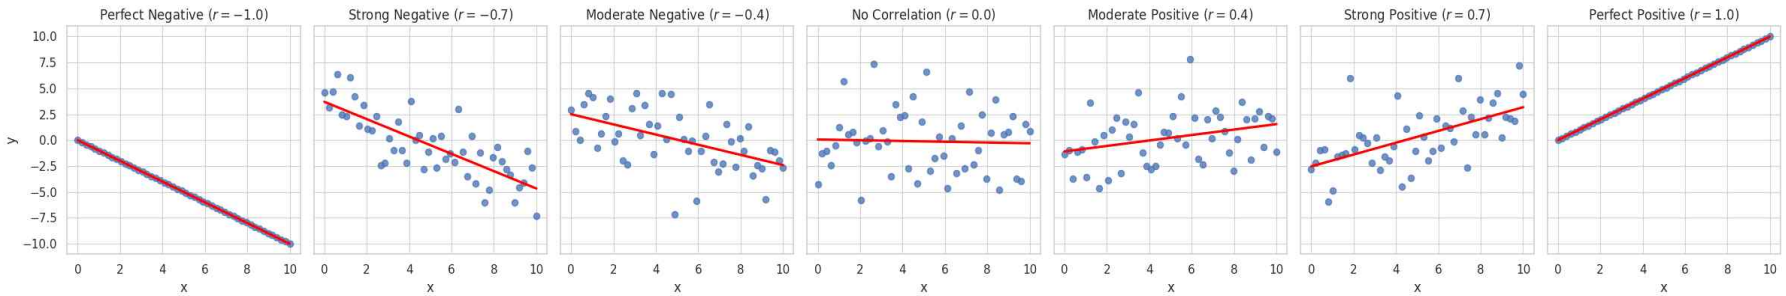
② 이와 반대가 되는 극단적인 경우, **두 변수 간 선형 관계가 완벽하게 선형일 때는** (perfectly linear) 상관계수의 값은 정확히 1이 될 것임

▸이는 아래 그림에서 모든 점이 하나의 선 위에 걸쳐 있는 것을 볼 수 있음



③ 이렇게 극단적인 경우가 아니라면, 두 변수의 직선 관계는 상관계수의 절대값을 0과 1 사이에 갖게 될 것임

- 관측값이 최적합선에 가까워질수록 두 변수 간 선형 관계는 더욱 뚜렷해지고 상관계수의 절대값은 증가할 것임
- 아래 그림은 상관계수가 -1에서 1까지 걸쳐 있는 두 변수의 산점도를 나타내는 데, 상관계수가 -1, -0.7, -0.4, 0, 0.4, 0.7, 1인 것을 왼쪽부터 순서대로 그림



□ 종합하면,

o r = 1 : 완전한 양(+)의 선형관계

o r = -1 : 완전한 음(-)의 선형관계

o r ≈ 0 : 뚜렷한 선형관계가 없음

6.2 상관관계의 계산

□ 상관계수는 두 변수가 각각 자신의 평균으로부터 얼마나 떨어져 있는지를 이용하여 계산

□ 상관계수의 공식을 이해하기 위해서는 먼저 **z-scores**에 대해 학습할 필요

- o **z-score**는 각 관측값이 평균에서 몇 표준편차만큼 떨어져 있는지를 나타냄

□ 먼저 X와 Y의 각 관측값을 평균과 표준편차를 이용하여 아래와 같이 **z-score로** 표준화

$$z_{X_i} = \frac{X_i - \overline{X}}{sd(X)}, \qquad z_{Y_i} = \frac{Y_i - \overline{Y}}{sd(Y)}$$

- o 위에서
  - X_i는 X의 특정 값을, i는 그 관측값의 위치를 표시
  - z_{X_i}는 관측값 X_i의 z-score를, z_{Y_i}는 관측값 Y_i의 z-score를 표시
  - $\overline{X}$는 X의 평균을, $\overline{Y}$는 Y의 평균을 표시
  - $sd(X)$는 X의 표준편차를, $sd(Y)$는 Y의 표준편차를 표시

□ 표본 상관계수는 두 변수의 표준화된 값이 함께 움직이는 정도를 측정

$$r = \frac{1}{n-1}\sum_{i=1}^{n} z_{X_i} z_{Y_i}$$

□ 이를 원래 변수로 나타내면

$$r = \frac{\sum_{i=1}^{n}(X_i - X)(Y_i - Y)}{\sqrt{\sum_{i=1}^{n}(X_i - \overline{X})^2}\sqrt{\sum_{i=1}^{n}(Y_i - \overline{Y})^2}}$$

◆ 해석

□ X_i와 Y_i가 모두 각자의 평균보다 크거나, 모두 평균보다 작으면 $z_{X_i} z_{Y_i} > 0$

→ 양(+)의 상관관계에 기여

□ X_i와 Y_i 중에서 하나는 평균보다 크고 다른 하나는 평균보다 작으면 $z_{X_i} z_{Y_i} < 0$

→ 음(-)의 상관관계에 기여

◇ 상관계수는 두 변수가 각자의 평균을 기준으로 같은 방향으로 움직이는가, 반대 방향으

로 움직이는가를 측정

<참고> **표준편차의 개념**

□ **표준편차(standard deviations)**는 분포의 중앙에 대비한 변화(variation)의 양을 말하며, X의 표준편차는 아래와 같이 산출:

$$sd(X) = \sqrt{\frac{\sum_{i=1}^{n}(X_i - \overline{X})^2}{n}}$$

$$= \sqrt{\frac{(X_1 - \overline{X})^2 + (X_2 - \overline{X})^2 + \cdots + (X_n - \overline{X})^2}{n}}$$

o 위에서

- $sd(X)$는 X의 표준편차를 표시
- n는 해당 변수에 있는 관측값 수
- $\sum_{i=1}^{n}(X_i - \overline{X})^2$는 $i=1$부터 $i=n$까지 모든 $(X_i - \overline{X})^2$을 합계한 것을 의미

□ 대체로, 한 변수의 표준편차는 관측값들과 그 평균 간 평균 거리(distance)를 나타냄

o 예를 들어, 만일 $X = 2, 4, 6$이고, X의 측정단위가 meter라면, X의 평균은:

$$\overline{X} = \frac{\sum_{i=1}^{n} X_i}{n} = \frac{2+4+6}{3} = \frac{12}{4} = 4\,meters$$

o 각 i에 대해 $(X_i - \overline{X})$를 산출해 보면, 각 관측값과 X의 평균 간 거리를 이해 가능

- $i = 1$인 경우, $(X_1 - \overline{X}) = 2 - 4 = -2\,meters$
- $i = 2$인 경우, $(X_2 - \overline{X}) = 4 - 4 = 0\,meters$
- $i = 3$인 경우, $(X_3 - \overline{X}) = 6 - 4 = 2\,meters$

o 위의 $(X_i - \overline{X})$ 항의 **결과 값**은 음수와 양수를 둘 다 가질 수 있음

o **이 항의 평균**을 산출해 보면, 양의 거리는 음의 거리를 상쇄함

o 이러한 **상쇄(cancellation) 현상**을 피하기 위해서는, **분포의 중앙에서 벗어난 편차의 평균을 측정**하는 방법으로서 각 편차의 부호(signs)를 제거할 필요가 있음

o $(X_i - \overline{X})$을 **제곱**한 $(X_i - \overline{X})^2$는 각 관측값이 평균에서 벗어난 거리를 제곱하는 셈

- $i = 1$인 경우, $(X_1 - \overline{X})^2 = (2-4)^2 = (-2)^2 = 4 meters^2$
- $i = 2$인 경우, $(X_2 - \overline{X})^2 = (4-4)^2 = (0)^2 = 0 meters^2$
- $i = 3$인 경우, $(X_3 - \overline{X})^2 = (6-4)^2 = (2)^2 = 4 meters^2$

□ 모든 관측값에 적용된 **제곱 거리의 평균**을 산출하기 위해서는 제곱 거리를 더해서 관측값 수로 나누는 것이 필요

$$\frac{\sum_{i=1}^{n}(X_i - \overline{X})^2}{n} = \frac{(X_1 - \overline{X})^2 + (X_2 - \overline{X})^2 + (X_3 - \overline{X})^2}{3} = \frac{4+0+4}{3} = 2.67 meters^2$$

□ 원래의 변수와 동일한 측정 단위(meters)를 가진 관측값과 평균 간 평균 거리로 돌아가기 위해서는 모든 관측값에 적용된 제곱 거리의 평균에 제곱근을 산출하는 것임

$$sd(X) = \sqrt{\frac{\sum_{i=1}^{n}(X_i - \overline{X})^2}{n}} = \sqrt{2.67 meters^2} = 1.63 meters$$

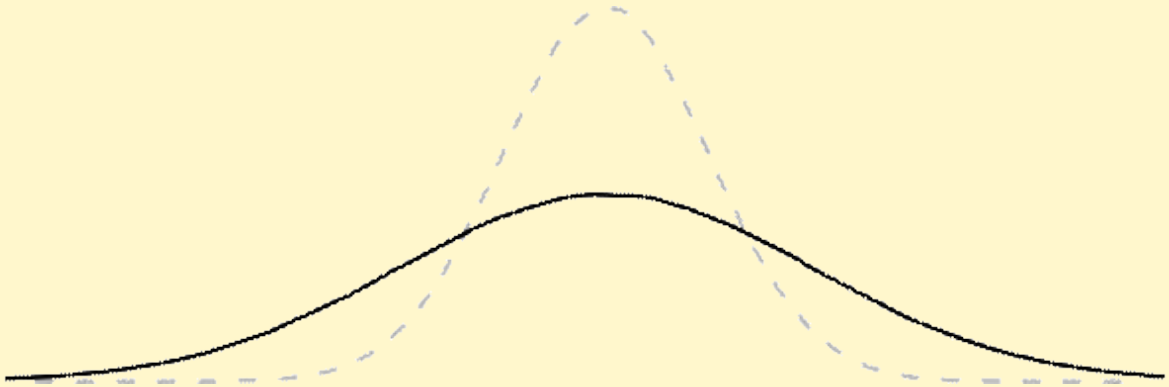
◆ **표준편차가 더 작다**는 것은 **평균적으로** 해당 관측값이 **평균에 더 가깝다**는 것을 뜻함

→ **분포**가 평균 근처에 집중되어 있으며, 그 결과, 중심에서 **밀도**는 더 높음

◆ **표준편차가 더 크다**는 것은 평균적으로 해당 관측값이 **평균에서 더 멀어져 있다**는 것을 시사

→ 분포가 분산되어 있으며, 그 결과, 중심에서 밀도는 더 낮음

□ 예) 아래 그림에서 점선으로 그려진 분포의 표준편차는 실선으로 그려진 분포의 표준편차보다 작음



6.3 산점도와 상관관계: Brexit 데이터

□ 실제 자료를 이용하여 산점도와 상관계수를 살펴봄

□ UK_districts.csv는 영국의 선거구별 Brexit 국민투표 결과와 교육수준에 관한 자료

o 아래 표는 데이터 셋에 포함된 변수 이름과 설명을 제시

o 자료에는 원래 382개 선거구가 있으며, 결측값을 제거하면 380개 선거구가 남음

변수	설명
name	선거구(the district) 이름
leave	해당 선거구의 Brexit 찬성비율(%)
high_education	대졸, 전문자격증 등을 가진 해당 선거구의 주민 비율(%)

(1) 데이터 불러오기

```
import pandas as pd

file_path = r'D:\Regression\UK_districts.csv'
dis = pd.read_csv(file_path, encoding='latin-1')

dis1 = dis.dropna()

print(dis1.shape)
```

```
(380, 3)
```

```
print(dis1.head())
```

```
                name  leave  high_education
0         Birmingham  50.42           22.98
1            Cardiff  39.98           32.33
2     Edinburgh City  25.56           21.92
3        Glasgow City  33.41           25.91
4          Liverpool   41.8           22.44
```

◇ 코드 설명

□ dis.dropna() 함수를 사용하여 결측값을 제거하여 dis1으로 저장

□ dis1.shape을 사용하여 데이터 셋에 있는 관측값의 수를 확인

o (주의) dis1.shape는 속성(attribute)이지, 함수가 아니므로 dis1.shape는 괄호 없이 사용함

▸ dis.shape는 (행의 수, 열의 수)를 담고 있는 튜플(tuple)

▸ dis.shape()처럼 괄호를 붙이면, 파이썬은 이것을 함수로 호출하려고 시도하지만, 실제는 튜플이기 때문에 호출이 불가능해 TypeError가 발생

□ 원래의 데이터 프레임은 382개 선거구에 관한 정보를 담고 있는데, 결측값이 제거된 데이터 셋에는 선거구가 380개 남아 있으며, 이는 2개 선거구가 제거되었음을 의미

6.3.1 산점도(Scatter Plots)

□ high_education과 leave의 관계를 시각적으로 살펴보기 위해 산점도를 그림

- o x축: 고학력 주민 비율(high_education)
- o y축: Brexit 찬성 비율(leave)

① 단순한 산점도

```
import matplotlib.pyplot as plt

plt.figure(figsize=(8, 6))
plt.scatter( dis1["high_education"], dis1["leave"] )

plt.xlabel("High education (%)")
plt.ylabel("Leave vote (%)")
plt.title("Education and Brexit Leave Vote")

plt.show()
```

2 산점도에 Birmingham을 빨간색 점으로 강조하고 화살표와 이름을 추가

```
import matplotlib.pyplot as plt

plt.figure(figsize=(8, 6))

# 전체 선거구의 산점도
plt.scatter(dis1['high_education'], dis1['leave'])

# Birmingham 점 추출
birmingham = dis1[dis1['name'] == 'Birmingham']

x_birm = birmingham['high_education'].values[0]
y_birm = birmingham['leave'].values[0]

# Birmingham을 빨간색 점으로 강조
plt.scatter(x_birm, y_birm, color='red', s=80, zorder=3)

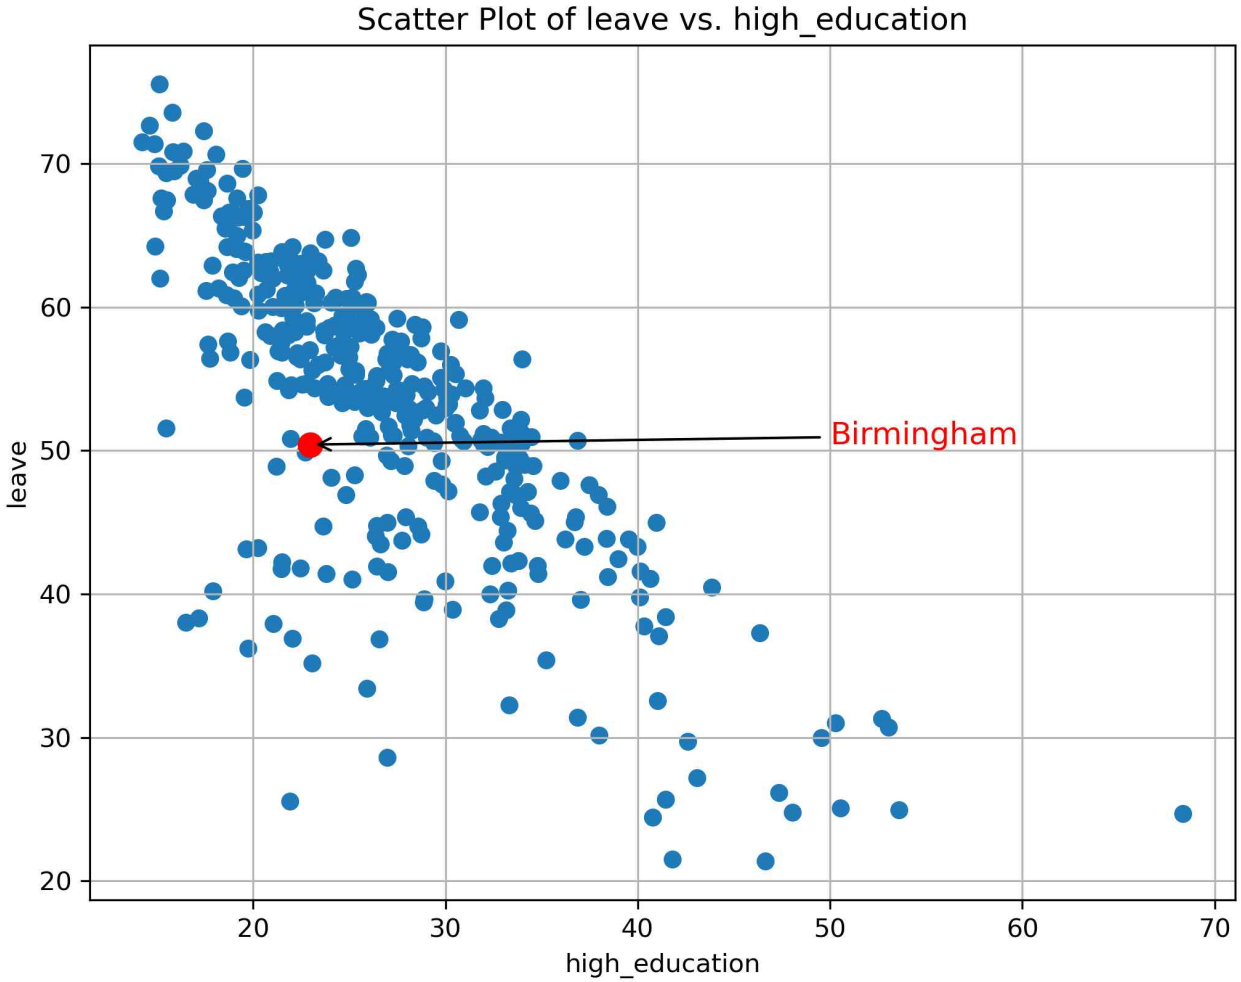

# Birmingham 이름과 화살표 추가
plt.annotate(
```

```
        'Birmingham',
        xy=(x_birm, y_birm),
        xytext=(50, 50),
        arrowprops=dict(facecolor='red', arrowstyle='->'),
        fontsize=12,
        color='red',
        ha='left',
        va='bottom'
)

plt.title('Scatter Plot of leave vs. high_education')
plt.xlabel('high_education')
plt.ylabel('leave')

plt.grid(True)

# PNG 파일로 저장
plt.savefig(r'D:\Regression\scatter_birmingham.png', dpi=300)
plt.show()
```


Scatter Plot of leave vs. high_education
leave
high_education
Birmingham
70
60
50
40
30
20
20
30
40
50
60
70

◇ 코드 설명

□ plt.scatter()는 두 변수의 관측값을 점으로 표시하여 두 변수 사이의 관계를 시각적으로 확인하는 함수

o dis1['high_education']과 dis1['leave']를 x, y축 값으로 삼아 관측값을 점으로 표시

□ birmingham = dis1[dis1['name'] == 'Birmingham']

o Birmingham만 별도로 추출하여 강조

o dis1['name'] == 'Birmingham': name이 Birmingham인 행을 선택

□ x_birm = birmingham['high_education'].values[0]
y_birm = birmingham['leave'].values[0]

o x_birm, y_birm)은 산점도에서 Birmingham의 실제 위치가 됨

o .values[0]: 선택된 값에서 첫 번째 값을 가져옴

□ plt.scatter(x_birm, y_birm, color='red', s=80, zorder=3)

o Birmingham 데이터만 따로 추출해서 빨간색(color='red')으로 표시.
s=80은 점의 크기, zorder=3은 점이 다른 요소 위에 표시

□ plt.annotate()는 그래프의 특정 관측값에 주석(텍스트와 화살표)을 추가하는 함수

o xy=(x_birm, y_birm) : 화살표가 가리키는 실제 Birmingham 관측값의 위치

o xytext=(50, 50) : 'Birmingham'이라는 텍스트가 좌표(50, 50)에 표시되는 위치

o arrowprops=dict(facecolor='red', arrowstyle='->') : 빨간색 화살표로 점과 텍스트를 연결

o ha='left', va='bottom' : xytext=(50, 50)을 텍스트의 왼쪽 아래 기준점으로 삼아 Birmingham 글자를 배치

▸ ha : 텍스트의 수평 정렬(horizontal alignment)을 지정
▸ va : 텍스트의 수직 정렬(vertical alignment)을 지정

◆ 산점도의 해석

□ 산점도를 보면 high_education이 높은 선거구일수록 leave가 낮아지는 우하향하는 관계가 나타남

□ 따라서 두 변수 사이에 음(-)의 선형관계가 있을 가능성을 시각적으로 확인할 수 있음

□ 그러나 산점도만으로는 관계의 강도를 하나의 숫자로 나타내기 어려우므로, 다음 단계에서 상관계수를 계산

6.3.2 상관관계: 교육수준과 Brexit 찬성률 간 관계

◇ 산점도만으로는 두 변수 간 선형관계의 방향과 강도를 하나의 숫자로 나타내기 어려우므로, 이를 하나의 숫자로 요약하는 상관계수(correlation coefficient)를 계산

(1) pandas를 이용한 상관계수 계산

□ pandas에서는 corr() 메서드를 이용하여 두 변수의 상관계수를 계산할 수 있음

```
corr1 = dis1['high_education'].corr(dis1['leave'])
corr2 = dis1['leave'].corr(dis1['high_education'])

print(corr1)
print(corr2)
-0.7633184963008873
-0.7633184963008873
```

□ 두 변수의 순서를 바꾸어도 상관계수는 동일: $r_{XY} = r_{YX}$

(2) numpy를 이용한 상관계수 계산

□ numpy의 corrcoef() 함수를 이용하여 상관계수를 계산

```
import numpy as np

corr_matrix = np.corrcoef( dis1['high_education'], dis1['leave'] )

print(corr_matrix)
```

□ corrcoef()는 하나의 상관계수 값이 아니라 상관행렬(correlation matrix)을 반환

```
[[ 1.         -0.7633185]
 [-0.7633185  1.       ]]
```

- o 대각선의 1: 자기 자신과의 상관계수
- o 대각선 밖의 -0.7633: high_education과 leave의 상관계수
- o 두 변수 사이의 상관계수만 가져오려면

  print(corr_matrix[0, 1]) 또는 print(corr_matrix[1, 0])

(3) 상관계수의 해석

□ high_education과 leave 사이의 상관계수는 r = -0.76

□ 먼저 부호(sign)를 살펴보면 r < 0 이므로 두 변수 사이에는 음(-)의 선형관계가 있음

- o 고학력 주민의 비율이 높은 선거구일수록 Brexit 찬성률이 낮은 경향
- o 반대로 고학력 주민의 비율이 낮은 선거구일수록 Brexit 찬성률이 높은 경향

□ 다음으로 절대값을 보면 $|r|$ = 76 으로 0보다는 1에 가까우므로 두 변수 사이에 비교적 강한 음의 선형관계가 나타남

◆ 주의

□ -0.76이라는 상관계수를 교육수준이 높아지면 Brexit 찬성률이 낮아진다고 인과적으로 해석할 수는 없음 → 상관관계 $\neq$ 인과관계

□ 제시된 결과는 교육수준이 높은 선거구일수록 Brexit 찬성률이 낮은 경향이 나타난다는 통계적 관계를 보여줌

◆ 상관관계를 해석할 때 주의 사항

❶ 변수의 순서를 바꾸어도 상관계수는 동일

□ Y와 X 간 상관계수는 X와 Y 간 상관계수와 동일하며, 수학으로 아래와 같음

$$cor(Y, X) = cor(X, Y)$$

- o 따라서 두 변수의 순서를 바꾸어도 선형관계의 방향과 강도는 변하지 않음
- o 예: $Corr(high_education, leave) = Corr(leave, high_education)$ = -0.7633

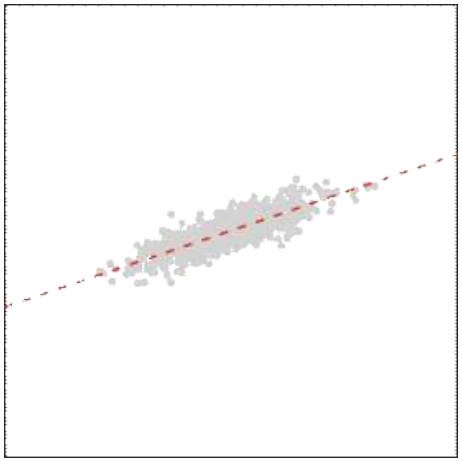
❷ 회귀선의 기울기와 상관관계의 강도는 서로 다른 개념

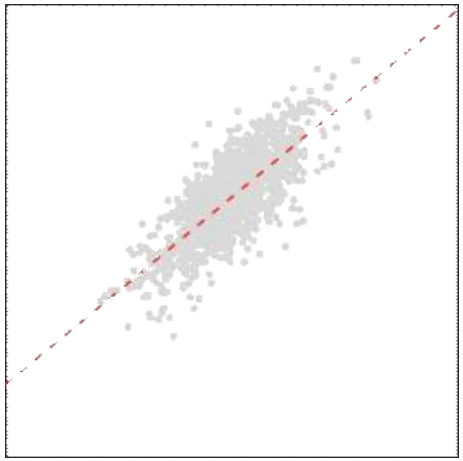
□ 회귀선의 기울기가 가파르다고 해서 반드시 상관관계가 강한 것은 아님

- o 회귀선의 기울기는 X가 1단위 변할 때 Y가 얼마나 변하는지를 나타냄
- o 상관계수의 절대값 $|r|$은 두 변수 사이의 선형관계가 얼마나 강한지를 나타냄

□ 따라서 상관관계의 강도는 기울기의 크기보다는 관측값들이 하나의 직선적인 패턴에 얼마나 밀접하게 모여 있는가와 관련됨

o 예: 오른쪽 그림의 회귀선이 더 가파르더라도 관측값들이 회귀선에서 더 넓게 흩어져 있다면, 왼쪽 그림보다 상관계수의 절대값이 작을 수 있음.





❸ 상관계수가 0이라고 두 변수 사이에 관계가 없는 것은 아님

□ 상관계수가 0 또는 0에 가깝다는 것은 두 변수 사이에 선형관계가 없거나 약하다는 것을 의미

o 두 변수 사이에 강한 비선형관계(nonlinear relationship)가 존재하더라도 상관계수는 0에 가까울 수 있음

o 예: 두 변수 사이에 $Y = X^2$와 같은 포물선 관계가 존재한다면 X와 Y는 분명한 관계를 가지고 있음

▸그러나 증가하는 부분과 감소하는 부분이 함께 존재하므로 전체적인 선형관계는 약하게 나타날 수 있음

o 따라서 상관계수만 확인하지 말고 산점도를 함께 살펴보는 것이 중요



❹ 상관관계는 인과관계(causation)를 의미하지 않음

□ 두 변수 사이에 강한 상관관계가 존재한다고 해서 한 변수의 변화가 다른 변수의 변화를 원인으로서 발생시킨다고 결론 내릴 수는 없음

□ 앞의 분석에서 high_education과 leave 사이에는 뚜렷한 음(-)의 상관관계가 나타남 (r = -0.7633)

o 그러나 이 결과만으로 교육수준이 높아지면 Brexit 찬성률이 낮아진다고 결론 내릴 수 없음

o 두 변수에 동시에 영향을 미치는 다른 요인이 존재할 수 있기 때문

▸ 예: 지역의 경제적 여건 등

◆ 허위관계(spurious relationship)

□ 두 변수 사이에 통계적 관계가 관찰되지만, 그 관계가 두 변수 사이의 직접적인 인과관계가 아니라 제3의 요인 등에 의해 나타난 관계

o 허위 상관(spurious correlation) 또는 허구적 상관은 둘 이상의 변수가 통계적으로 상관되어 있지만 인과관계가 없는 관계

